Оптимизизация маркетинговых затрат согласно данным от Яндекс.Афиши

Описание проекта

Поможем маркетологам в оптимизизации маркетинговых затрат согласно следующим данным от Яндекс.Афиши с июня 2017 по конец мая 2018 года:

- лог сервера с данными о посещениях сайта Яндекс.Афиши,
- выгрузка всех заказов за этот период,
- статистика рекламных расходов.

Изучим:

- как люди пользуются продуктом,
- когда они начинают покупать,
- сколько денег приносит каждый клиент,
- когда клиент окупается.

Шаг 1. Загрузим данные и подготовим их к анализу

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import math
from IPython.display import display
from scipy import stats as st

visits_log = pd.read_csv('/datasets/visits_log.csv')
orders_log = pd.read_csv('/datasets/orders_log.csv')
costs = pd.read_csv('/datasets/costs.csv')
```

In [2]:
```
visits_log.info()
```
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 359400 entries, 0 to 359399
Data columns (total 5 columns):
Device       359400 non-null object
End Ts       359400 non-null object
Source Id    359400 non-null int64
Start Ts     359400 non-null object
Uid          359400 non-null uint64
dtypes: int64(1), object(3), uint64(1)
memory usage: 13.7+ MB
```

Таблица `visits_log` (лог сервера с информацией о посещениях сайта):

- *Device* — категория устройства пользователя;
- *End Ts* — дата и время окончания сессии;
- *Source Id* — идентификатор рекламного источника, из которого пришел пользователь;
- *Start Ts* — дата и время начала сессии;
- *Uid* — уникальный идентификатор пользователя.

Датасет состоит из 5 столбцов и 359400 строк. Пропуски отсутствуют. Изменим названия столбцов:

- *Device* — на *device*;
- *End Ts* — на *session_end_ts*;
- *Source Id* — на *source_id*;
- *Start Ts* — на *session_start_ts*;
- *Uid* — на *user_id*.

In [3]:
```
visits_log.columns = ['device', 'session_end_ts', 'source_id', 'session_start_ts', 'user_id']
visits_log.info()
```
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 359400 entries, 0 to 359399
Data columns (total 5 columns):
device              359400 non-null object
session_end_ts      359400 non-null object
source_id           359400 non-null int64
session_start_ts    359400 non-null object
user_id             359400 non-null uint64
dtypes: int64(1), object(3), uint64(1)
memory usage: 13.7+ MB
```

In [4]:
```
orders_log.info()
```
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50415 entries, 0 to 50414
Data columns (total 3 columns):
Buy Ts     50415 non-null object
Revenue    50415 non-null float64
Uid        50415 non-null uint64
dtypes: float64(1), object(1), uint64(1)
memory usage: 1.2+ MB
```

Таблица `orders_log` (информация о заказах):

- *Buy Ts* — дата и время заказа;
- *Revenue* — выручка Яндекс.Афиши с этого заказа;
- *Uid* — уникальный id пользователя, который сделал заказ.

Датасет состоит из 3 столбцов и 50415 строк. Пропуски отсутствуют. Изменим названия столбцов:

- *Buy Ts* — на *order_ts*;
- *Revenue* — на *revenue*;
- *Uid* — на *user_id*.

In [5]:
```
orders_log.columns = ['order_ts', 'revenue', 'user_id']
orders_log.info()
```
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50415 entries, 0 to 50414
Data columns (total 3 columns):
order_ts    50415 non-null object
revenue     50415 non-null float64
user_id     50415 non-null uint64
dtypes: float64(1), object(1), uint64(1)
memory usage: 1.2+ MB
```

In [6]:
```
costs.info()
```
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2542 entries, 0 to 2541
Data columns (total 3 columns):
source_id    2542 non-null int64
dt           2542 non-null object
costs        2542 non-null float64
dtypes: float64(1), int64(1), object(1)
memory usage: 59.7+ KB
```

Таблица *costs* (информация о затратах на маркетинг):

- *source_id* — идентификатор рекламного источника;
- *dt* — дата;
- *costs* — затраты на этот рекламный источник в этот день.

Датасет состоит из 3 столбцов и 50415 строк. Пропуски отсутствуют. Названия столбцов не требуют изменений.

Изменим формат поля *source_id* таблицы `visits_log` с int64 на int16 методом `astype()`.

In [7]:
```
visits_log['source_id'] = visits_log['source_id'].astype(np.int16())
```

Преобразуем строки в столбцах *session_end_ts* и *session_start_ts* таблицы `visits_log` в формат даты.

In [8]:
```
visits_log['session_end_ts'] = pd.to_datetime(visits_log['session_end_ts'], format='%Y-%m-%dT%H:%M:%S')
visits_log['session_start_ts'] = pd.to_datetime(visits_log['session_start_ts'], format='%Y-%m-%dT%H:%
M:%S')
```

Преобразуем строки в столбце *order_ts* таблицы `orders_log` в формат даты.

In [9]:
```
orders_log['order_ts'] = pd.to_datetime(orders_log['order_ts'], format='%Y-%m-%dT%H:%M:%S')
```

Преобразуем строки в столбце *dt* таблицы `costs` в формат даты.

In [10]:
```
costs['dt'] = pd.to_datetime(costs['dt'], format='%Y-%m-%dT%H:%M:%S')
```

Вывод:

Данные распределены по трём датасетам: `visits_log`, `orders_log`, `costs`. Названия столбцов изменены. Пропуски и дубликаты отсутствуют, типы данных преобразованы.

In [11]:
```
visits_log.duplicated().sum()
```
Out[11]: 0

In [12]:
```
orders_log.duplicated().sum()
```
Out[12]: 0

In [13]:
```
costs.duplicated().sum()
```
Out[13]: 0

Шаг 2. Построим отчёты и посчитаем метрики

Продукт

- Посчитаем, сколько людей посещают сайт Яндекс.Афиши в день **DAU** (*daily active users*), неделю **WAU** (*weekly active users*), месяц **MAU** (*monthly active users*). Для этого выделим в отдельные столбцы год, месяц и неделю, а также полную дату.

In [14]:
```
visits_log['session_year']  = visits_log['session_start_ts'].dt.year
visits_log['session_month'] = visits_log['session_start_ts'].dt.month
visits_log['session_week']  = visits_log['session_start_ts'].dt.week
visits_log['session_date'] = visits_log['session_start_ts'].dt.date
```

Сгруппируем данные по уникальным пользователям и найдём среднее.

In [15]:
```
dau_total = visits_log.groupby('session_date').agg({'user_id': 'nunique'}).mean()
wau_total = visits_log.groupby(['session_year', 'session_week']).agg({'user_id': 'nunique'}).mean()
mau_total = visits_log.groupby(['session_year', 'session_month']).agg({'user_id': 'nunique'}).mean()
```

Количество уникальных пользователей в день:

In [16]:
```
dau_total
```
Out[16]:
```
user_id    907.991758
dtype: float64
```

Количество уникальных пользователей в неделю:

In [17]:
```
wau_total
```
Out[17]:
```
user_id    5716.245283
dtype: float64
```

Количество уникальных пользователей в месяц:

In [18]:
```
mau_total
```
Out[18]:
```
user_id    23228.416667
dtype: float64
```

- Посчитаем количество сессий в день. Для этого создадим сводную таблицу `sessions_number`, сгруппируем данные по дате, посчитаем общее количество и количество уникальных пользовательских сессий и выведем на экран.

In [19]:
```
sessions_number = visits_log.pivot_table(index='session_date', values='user_id', aggfunc=['count', 'nun
ique'])
sessions_number.head()
```
Out[19]:

	count	nunique	
	user_id	session_date	user_id
session_date			
2017-06-01	664	1	605
2017-06-02	658	1	608
2017-06-03	477	1	445
2017-06-04	510	1	476
2017-06-05	893	1	820

Построим график.

In [20]:
```
plt.figure(figsize=(12, 7))
sessions_number['count']['user_id'].plot()
sessions_number['nunique']['user_id'].plot()
plt.grid(True)
ax = plt.gca()
ax.set_xlabel('Год, месяц')
ax.set_ylabel('Количество сессий')
plt.title('Количество сессий (общее и уникальное) в день');
```

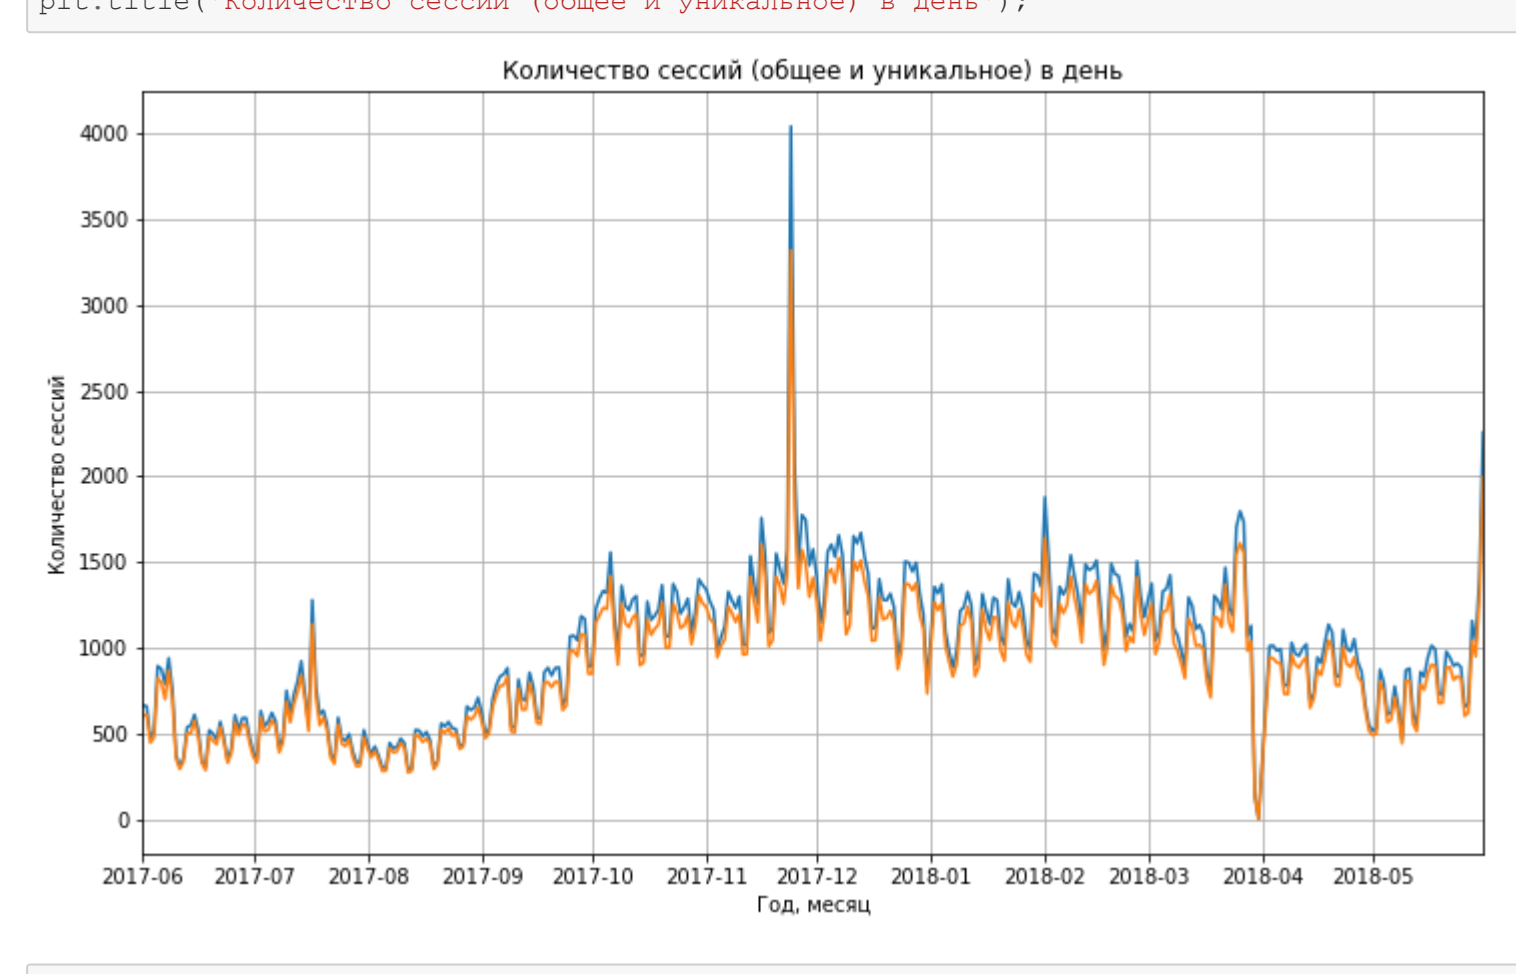

In [21]:
```
wau = visits_log.groupby(['session_year', 'session_week']).agg({'user_id': 'nunique'})
wau.plot(figsize=(12, 7), legend=False)
plt.grid(True)
ax = plt.gca()
ax.grid(which='minor')
ax.set_xlabel('Год, неделя')
ax.set_ylabel('Количество сессий')
plt.title('Количество уникальных пользовательских сессий в неделю');
```

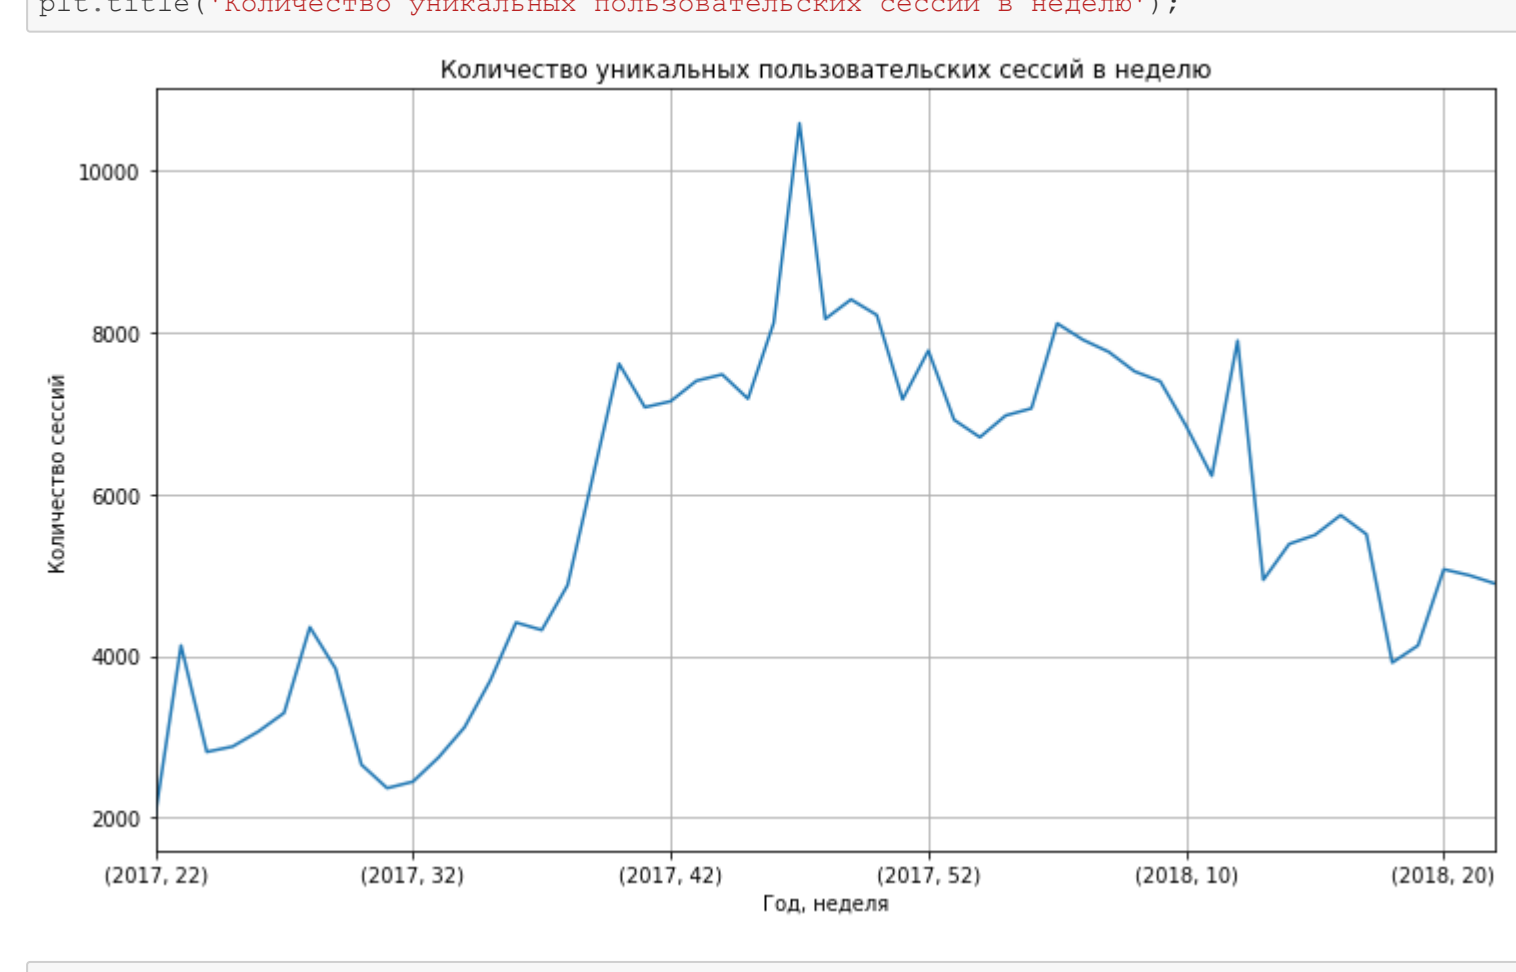

In [22]:
```
mau = visits_log.groupby(['session_year', 'session_month']).agg({'user_id': 'nunique'})
mau.plot(figsize=(12, 7), legend=False)
plt.grid(True)
ax = plt.gca()
ax.set_xlabel('Год, месяц')
ax.set_ylabel('Количество сессий')
plt.title('Количество уникальных пользовательских сессий в месяц');
```

Найдём дату пикового значения.

In [23]:
```
sessions_number[sessions_number['count']['user_id'] == sessions_number['count']['user_id'].max()]
```
Out[23]:

	count	nunique	
	user_id	session_date	user_id
session_date			
2017-11-24	4042	1	3319

Вывод: пик пришёлся на 24-е ноября. Аномалия? Подготовка к Новому году? Иные причины?

- Посчитаем, сколько длится одна сессия. Найдём разницу между окончанием и началом сессии в секундах, поделим на 60,чтобы найти минуты, сохраним результат в столбец *session_duration_min*.

In [24]:
```
visits_log['session_duration_min'] = (visits_log['session_end_ts'] - visits_log['session_start_ts']).dt
.seconds / 60
```

Проанализируем *session_duration_min* методом `describe()`.

In [25]:
```
visits_log['session_duration_min'].describe()
```
Out[25]:
```
count    359400.000000
mean         10.725108
std          16.938913
min           0.000000
25%           2.000000
50%           5.000000
75%          14.000000
max        1408.000000
Name: session_duration_min, dtype: float64
```

На основании результата построим гистограмму распределения продолжительности сессий, ограничив продолжительность 50 минутами.

In [26]:
```
visits_log[visits_log['session_duration_min'] > 0]['session_duration_min'].hist(range=(1, 50), figsize=
(12, 7), bins=99)
ax = plt.gca()
ax.set_xlabel('Длительность (в минутах)')
ax.set_ylabel('Количество сессий')
plt.title('Гистограмма распределения продолжительности сессий с 1 по 50 (в минутах)');
```

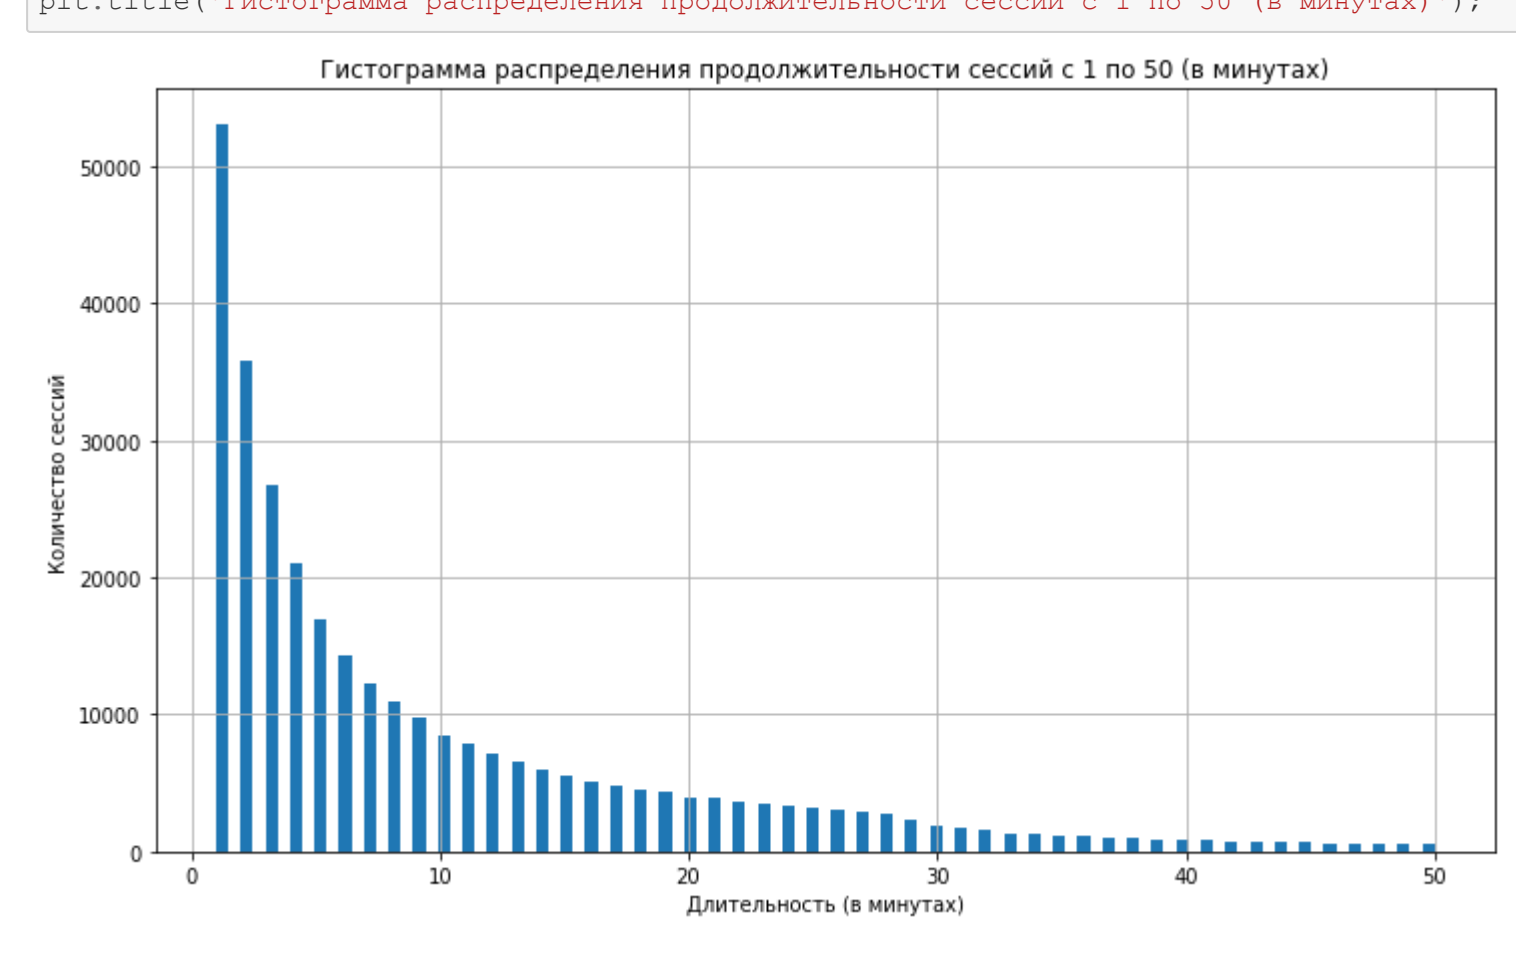

Вывод: чаще всего встречается значение 1, средняя продолжительность сессии (**ASL** — *average session length*) составляет одну минуту.

In [27]:
```
visits_log['session_duration_min'].mean()
```
Out[27]: 10.725108143201632

In [28]:
```
visits_log['session_duration_min'].median()
```
Out[28]: 5.0

- Исследуем, как часто люди возвращаются при помощи когортного анализа. Сформируем когорты по посещениям.

In [29]:
```
first_visit_date_by_users = visits_log.groupby('user_id')['session_start_ts'].min()
first_visit_date_by_users.name = 'first_visit_date'
visits_log = visits_log.join(first_visit_date_by_users,on='user_id')
visits_log['visit_month'] = visits_log['session_start_ts'].astype('datetime64[M]')
visits_log['first_visit_date'] = visits_log['first_visit_date'].astype('datetime64[M]')
```

Построим сводную таблицу методом `pivot_table()`:

- в строках *index* когорта пользователей *first_visit_date*;
- в столбцах *columns* — месяц посещения *session_month*;
- значениями *values* — количество уникальных пользователей *user_id*;
- в аргументе *aggfunc* укажем *nunique*.

In [30]:
```
user_session_pivot = visits_log.pivot_table(
    index='first_visit_date',
    columns='visit_month',
    values='user_id',
    aggfunc='nunique')
user_session_pivot
```
Out[30]:

visit_month	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01
first_visit_date												
2017-06-01	13259.0	1043.0	713.0	814.0	909.0	947.0	809.0	766.0	694.0	674.0	539.0	596.0
2017-07-01	NaN	13140.0	737.0	674.0	738.0	765.0	633.0	596.0	601.0	510.0	376.0	361.0
2017-08-01	NaN	NaN	10181.0	783.0	640.0	639.0	510.0	448.0	370.0	402.0	284.0	265.0
2017-09-01	NaN	NaN	NaN	16704.0	1428.0	1156.0	847.0	658.0	632.0	599.0	404.0	381.0
2017-10-01	NaN	NaN	NaN	NaN	25977.0	2042.0	1357.0	1012.0	890.0	837.0	555.0	529.0
2017-11-01	NaN	NaN	NaN	NaN	NaN	27248.0	2133.0	1202.0	1054.0	919.0	638.0	594.0
2017-12-01	NaN	NaN	NaN	NaN	NaN	NaN	25268.0	1410.0	960.0	786.0	512.0	481.0
2018-01-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	22624.0	1351.0	890.0	565.0	458.0
2018-02-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	22197.0	1267.0	565.0	446.0
2018-03-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	20589.0	861.0	557.0
2018-04-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	15709.0	760.0
2018-05-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	15273.0

In [31]:
```
plt.figure(figsize=(13, 9))
plt.title('Количество посещений по когортам пользователей')
sns.heatmap(user_session_pivot, cmap='Blues', annot=True, fmt='.1f', linewidths=1, linecolor='gray', vm
in=0, vmax=2500)
ax = plt.gca()
ax.set_xticklabels(user_session_pivot.columns.strftime('%Y-%m'))
ax.set_yticklabels(user_session_pivot.index.strftime('%Y-%m'))
ax.set_xlabel('Месяцы посещений')
ax.set_ylabel('Когорты пользователей');
```

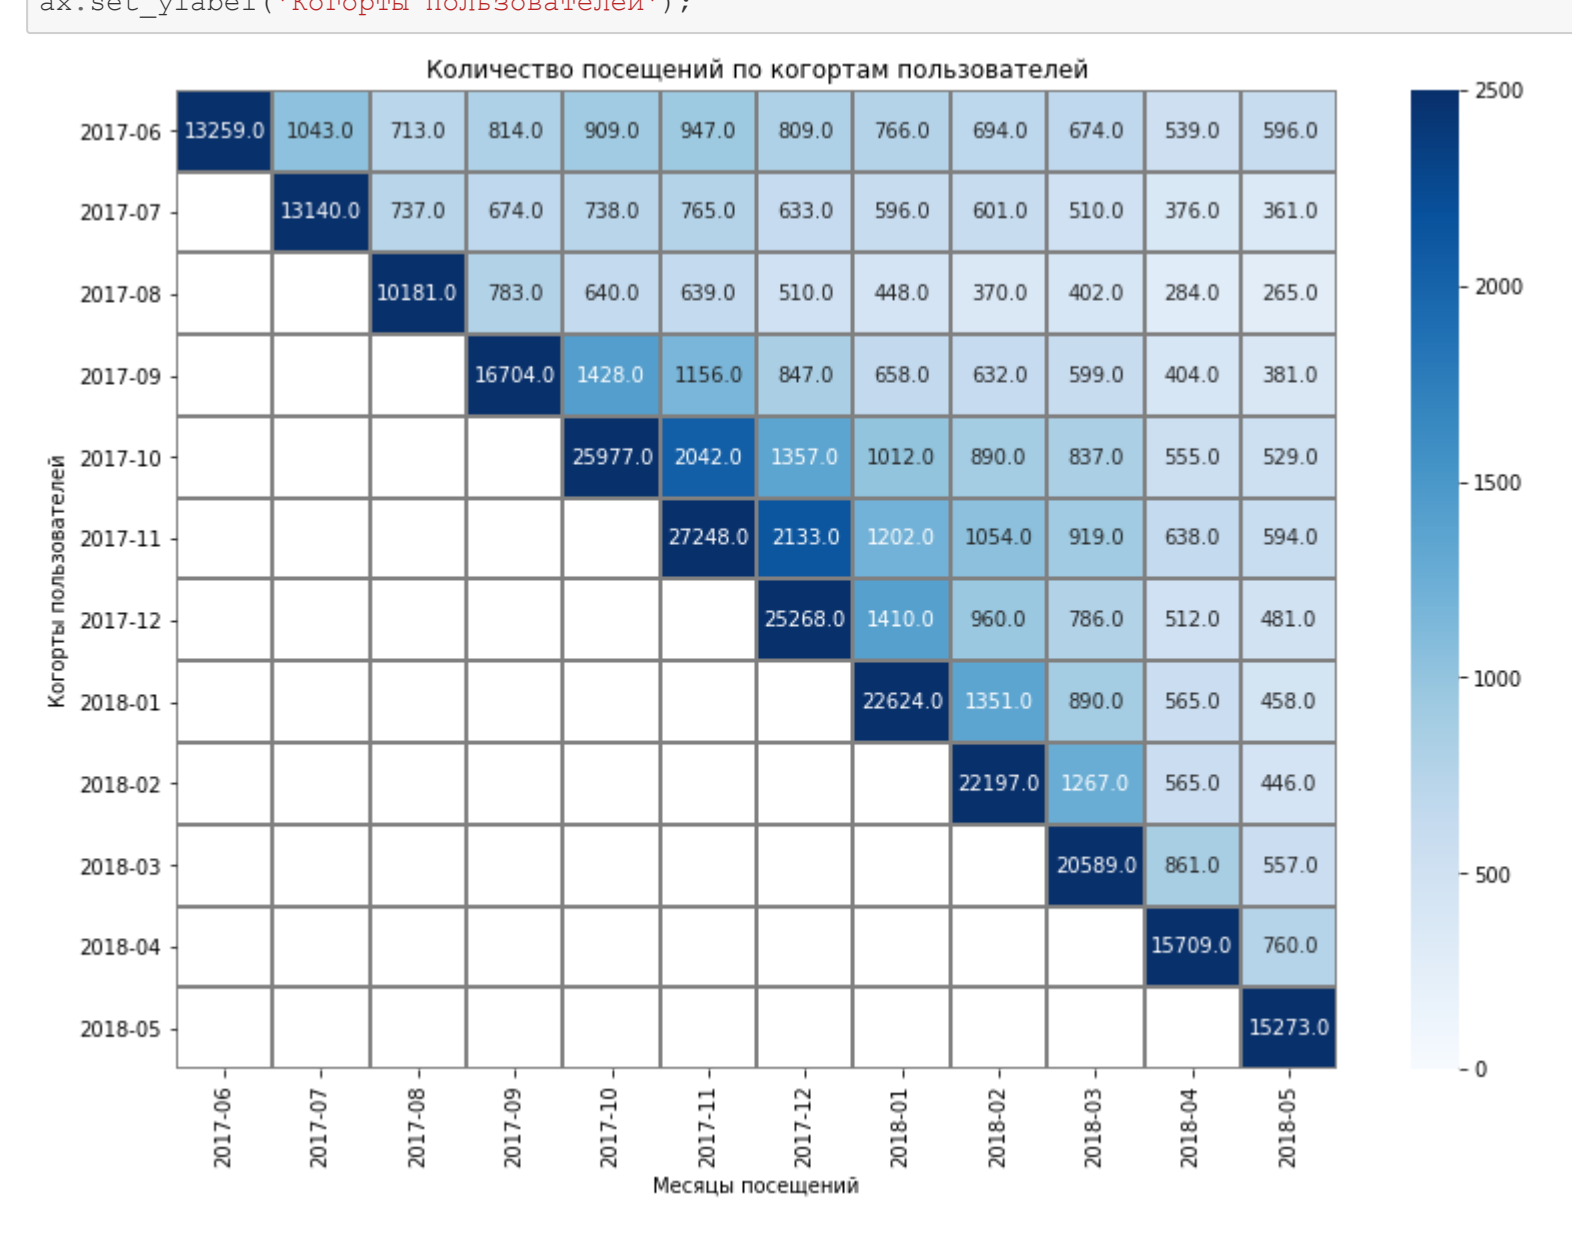

Вывод: после первого месяца количество посетителей в когорте резко снижается. Осенью действительно наблюдается всплеск посетителей.

Рассчитаем коэффициент удержания **Retention Rate**. Для каждой строки датафрейма вычислим *lifetime* пользователя в рамках когорты.

In [32]:
```
visits_log['cohort_lifetime'] = (visits_log['visit_month'] - visits_log['first_visit_date']) / np.timed
elta64(1,'M')
visits_log['cohort_lifetime'] = visits_log['cohort_lifetime'].round().astype('int')
```

Сгруппируем данные по когорте и *lifetime*. Посчитаем для каждой когорты количество активных пользователей на каждый месяц.

In [33]:
```
cohorts_retention_rate = visits_log.groupby(['first_visit_date','cohort_lifetime']).agg({'user_id':'nun
ique'}).reset_index()
cohorts_retention_rate.head()
```
Out[33]:

	first_visit_date	cohort_lifetime	user_id
0	2017-06-01	0	13259
1	2017-06-01	1	1043
2	2017-06-01	2	713
3	2017-06-01	3	814
4	2017-06-01	4	909

Найдём исходное количество пользователей в когорте. Возьмём их число на нулевую неделю.

In [34]:
```
initial_users_count = cohorts_retention_rate[cohorts_retention_rate['cohort_lifetime'] == 0][['first_vi
sit_date','user_id']]
initial_users_count
```
Out[34]:

	first_visit_date	user_id
0	2017-06-01	13259
12	2017-07-01	13140
23	2017-08-01	10181
33	2017-09-01	16704
42	2017-10-01	25977
50	2017-11-01	27248
57	2017-12-01	25268
63	2018-01-01	22624
68	2018-02-01	22197
72	2018-03-01	20589
75	2018-04-01	15709
77	2018-05-01	15273

Переименуем столбец *user_id* в *cohort_users* методом `rename()`. Параметру *columns* передадим словарь, где ключ — старое название столбца, а значение — новое.

In [35]:
```
initial_users_count = initial_users_count.rename(columns={'user_id':'cohort_users'})
initial_users_count
```
Out[35]:

	first_visit_date	cohort_users
0	2017-06-01	13259
12	2017-07-01	13140
23	2017-08-01	10181
33	2017-09-01	16704
42	2017-10-01	25977
50	2017-11-01	27248
57	2017-12-01	25268
63	2018-01-01	22624
68	2018-02-01	22197
72	2018-03-01	20589
75	2018-04-01	15709
77	2018-05-01	15273

Объединим данные по когортам с исходным количеством пользователей в когорте.

In [36]:
```
cohorts_retention_rate = cohorts_retention_rate.merge(initial_users_count,on='first_visit_date')
cohorts_retention_rate.head()
```
Out[36]:

	first_visit_date	cohort_lifetime	user_id	cohort_users
0	2017-06-01	0	13259	13259
1	2017-06-01	1	1043	13259
2	2017-06-01	2	713	13259
3	2017-06-01	3	814	13259
4	2017-06-01	4	909	13259

Наконец, рассчитаем **Retention Rate**. Разделим количество активных пользователей в каждый месяц на исходное число пользователей в когорте.

In [37]:
```
cohorts_retention_rate['retention'] = cohorts_retention_rate['user_id'] / cohorts_retention_rate['cohor
t_users']
```

Построим сводную таблицу и создадим тепловую карту.

In [38]:
```
retention_pivot = cohorts_retention_rate.pivot_table(
    index='first_visit_date',columns='cohort_lifetime',values='retention',aggfunc='sum')
retention_pivot
```
Out[38]:

cohort_lifetime	0	1	2	3	4	5	6	7	8	9	10	11
first_visit_date												
2017-06-01	1.0	0.078664	0.053775	0.061392	0.068557	0.071423	0.061015	0.057772	0.052342	0.050833	0.040652	0.044951
2017-07-01	1.0	0.056088	0.051294	0.056164	0.058219	0.048174	0.045358	0.045738	0.038813	0.028615	0.027473	NaN
2017-08-01	1.0	0.076908	0.062862	0.062764	0.050093	0.044004	0.036342	0.039485	0.027895	0.026029	NaN	NaN
2017-09-01	1.0	0.085489	0.069205	0.050706	0.039392	0.037835	0.035860	0.024186	0.022809	NaN	NaN	NaN
2017-10-01	1.0	0.078608	0.052239	0.038958	0.034261	0.032221	0.021365	0.020364	NaN	NaN	NaN	NaN
2017-11-01	1.0	0.078281	0.044113	0.038682	0.033727	0.023415	0.021800	NaN	NaN	NaN	NaN	NaN
2017-12-01	1.0	0.055802	0.037993	0.031107	0.020263	0.019036	NaN	NaN	NaN	NaN	NaN	NaN
2018-01-01	1.0	0.059715	0.039339	0.024973	0.020244	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-02-01	1.0	0.057080	0.025454	0.020093	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-03-01	1.0	0.041818	0.027053	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-04-01	1.0	0.048380	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-05-01	1.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

In [39]:
```
plt.figure(figsize=(13, 9))
plt.title('Коэффициент удержания по когортам пользователей')
sns.heatmap(retention_pivot, cmap='Blues', annot=True, fmt='.1%', linewidths=1, linecolor='gray', vmin=
0, vmax=0.1)
ax = plt.gca()
ax.set_yticklabels(retention_pivot.index.strftime('%Y-%m'))
ax.set_xlabel('Время жизни когорт')
ax.set_ylabel('Когорты пользователей');
```

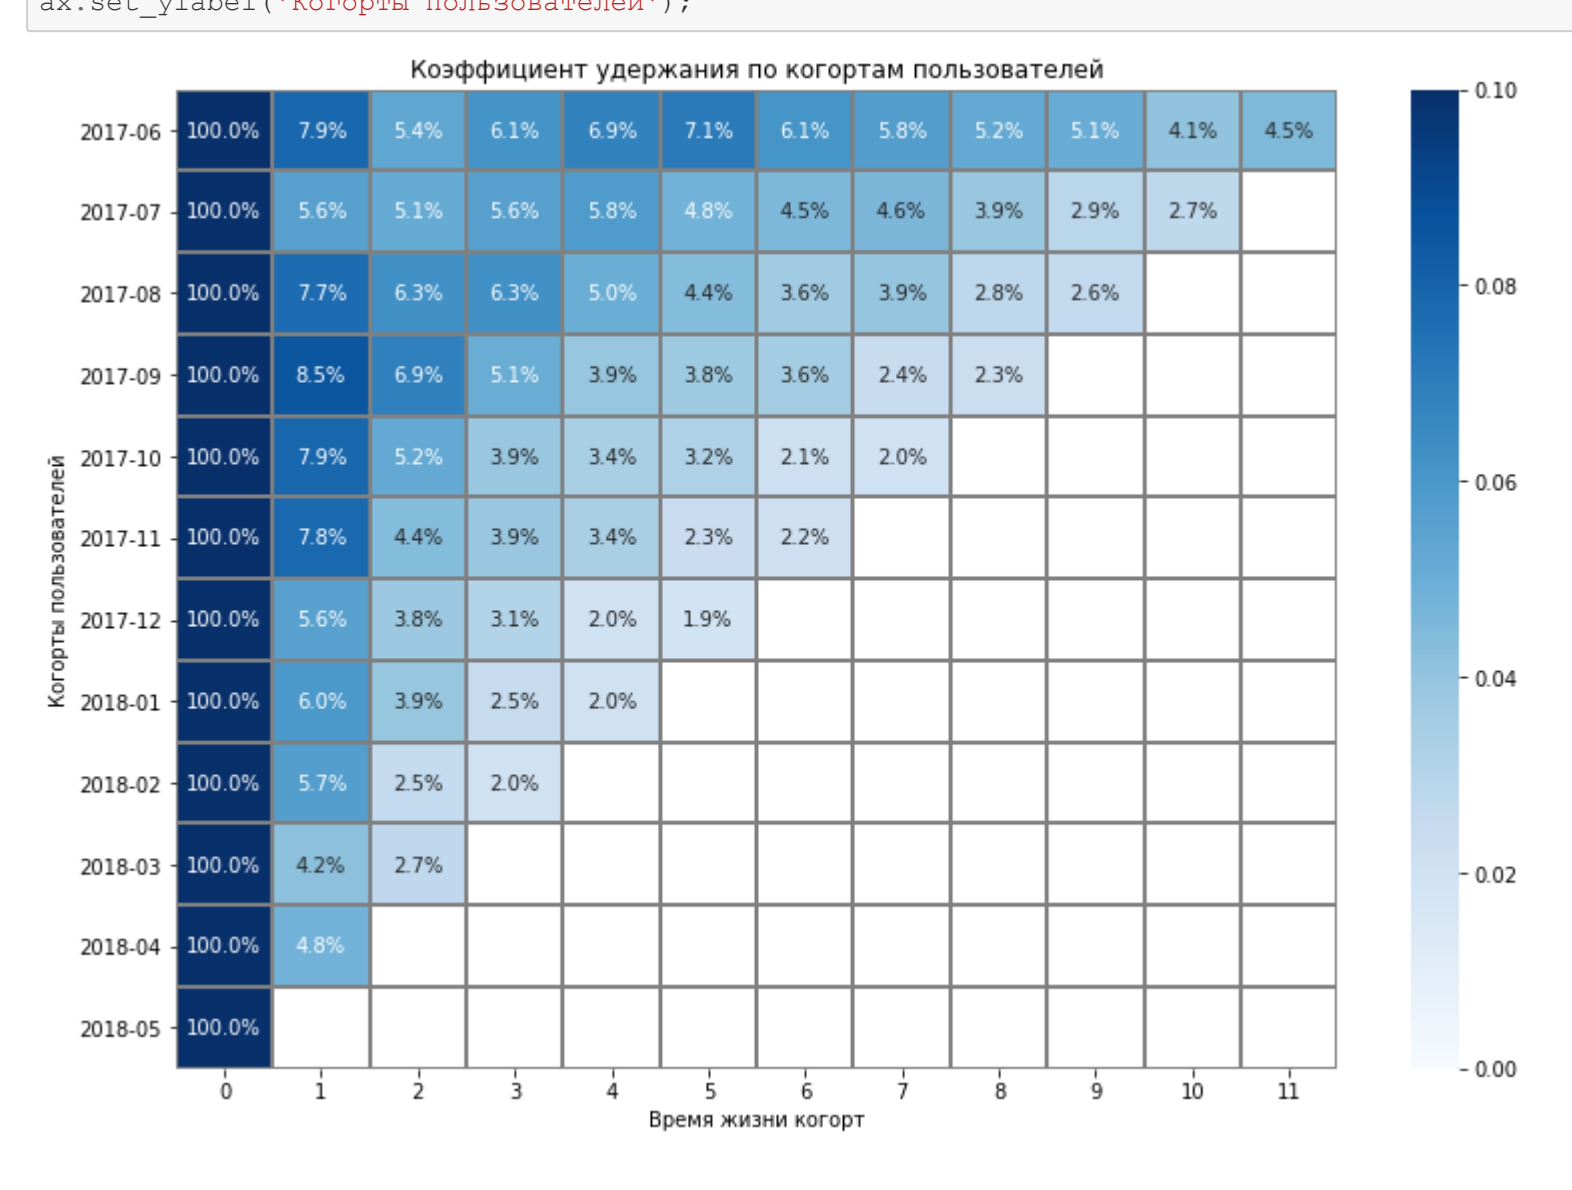

Вывод: после первого месяца количество посетителей в когорте резко снижается.

Продажи

- Посчитаем, когда люди начинают покупать. Найдём дату первой покупки, сгруппируем пользователей таблицы `orders_log`, определим самое раннее время, сохраним результат в таблицу `first_order_date_by_users` и выведем на экран.

In [40]:
```
first_order_date_by_users = orders_log.groupby('user_id')['order_ts'].min()
first_order_date_by_users.name = 'first_order_month'
first_order_date_by_users.head()
```
Out[40]:
```
user_id
313578113262317     2018-01-03 21:51:00
1575281904278712    2017-06-03 10:13:00
2429014661409475    2017-10-11 18:33:00
2464366381792757    2018-01-28 15:54:00
2551852515556206    2017-11-24 10:14:00
Name: first_order_month, dtype: datetime64[ns]
```

Найдём разницу между таблицами `first_order_date_by_users` и `first_visit_date_by_users`. Сохраним результат в переменную `order_time`, удалим пропуски и проанализируем методом `describe()`.

In [41]:
```
order_time = first_order_date_by_users - first_visit_date_by_users
order_time = order_time.dropna()
order_time.describe()
```
Out[41]:
```
count                       36523
mean     16 days 21:40:10.550064
std      47 days 01:44:46.481416
min              0 days 00:00:00
25%              0 days 00:04:00
50%              0 days 00:16:00
75%              2 days 00:17:00
max            363 days 07:04:00
dtype: object
```

Вывод: когда люди начинают покупать? Сразу. Если они не купили ничего в первые 15 минут и не вернулись через пару дней, то, скорее всего, уже ничего не купят.

In [42]:
```
order_time.mean()
```
Out[42]: Timedelta('16 days 21:40:10.550064')

In [43]:
```
order_time.median()
```
Out[43]: Timedelta('0 days 00:16:00')

In [44]:
```
order_time.astype('timedelta64[m]')[order_time.astype('timedelta64[m]') <= 60].hist(figsize=(12, 7), bi
ns=121)
ax = plt.gca()
ax.set_xlabel('Время от начала сессии (в минутах)')
ax.set_ylabel('Количество покупок')
plt.title('Гистограмма распределения времени начала покупки от 0 до 60 минут');
```

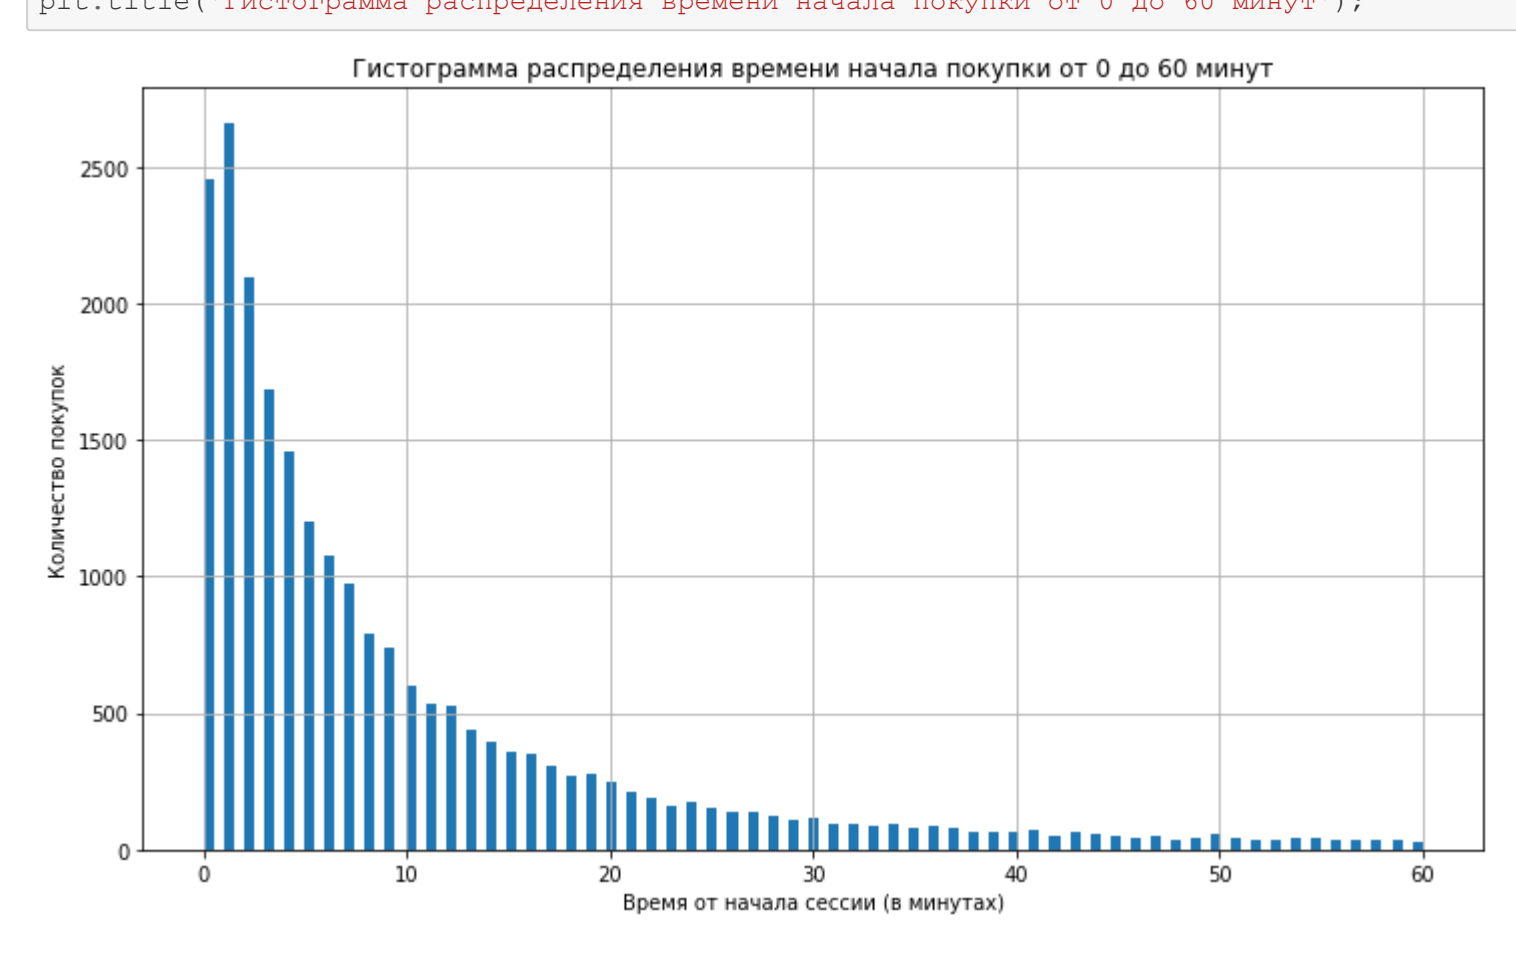

```
In [45]: order_time.astype('timedelta64[D]')[order_time.astype('timedelta64[D]') <= 10].hist(figsize=(12, 7), bins=10)
ax = plt.gca()
ax.set_xlabel('Время от начала сессии (в днях)')
ax.set_ylabel('Количество покупок')
plt.title('Гистограмма распределения времени начала покупки от 0 до 10 дней');
```

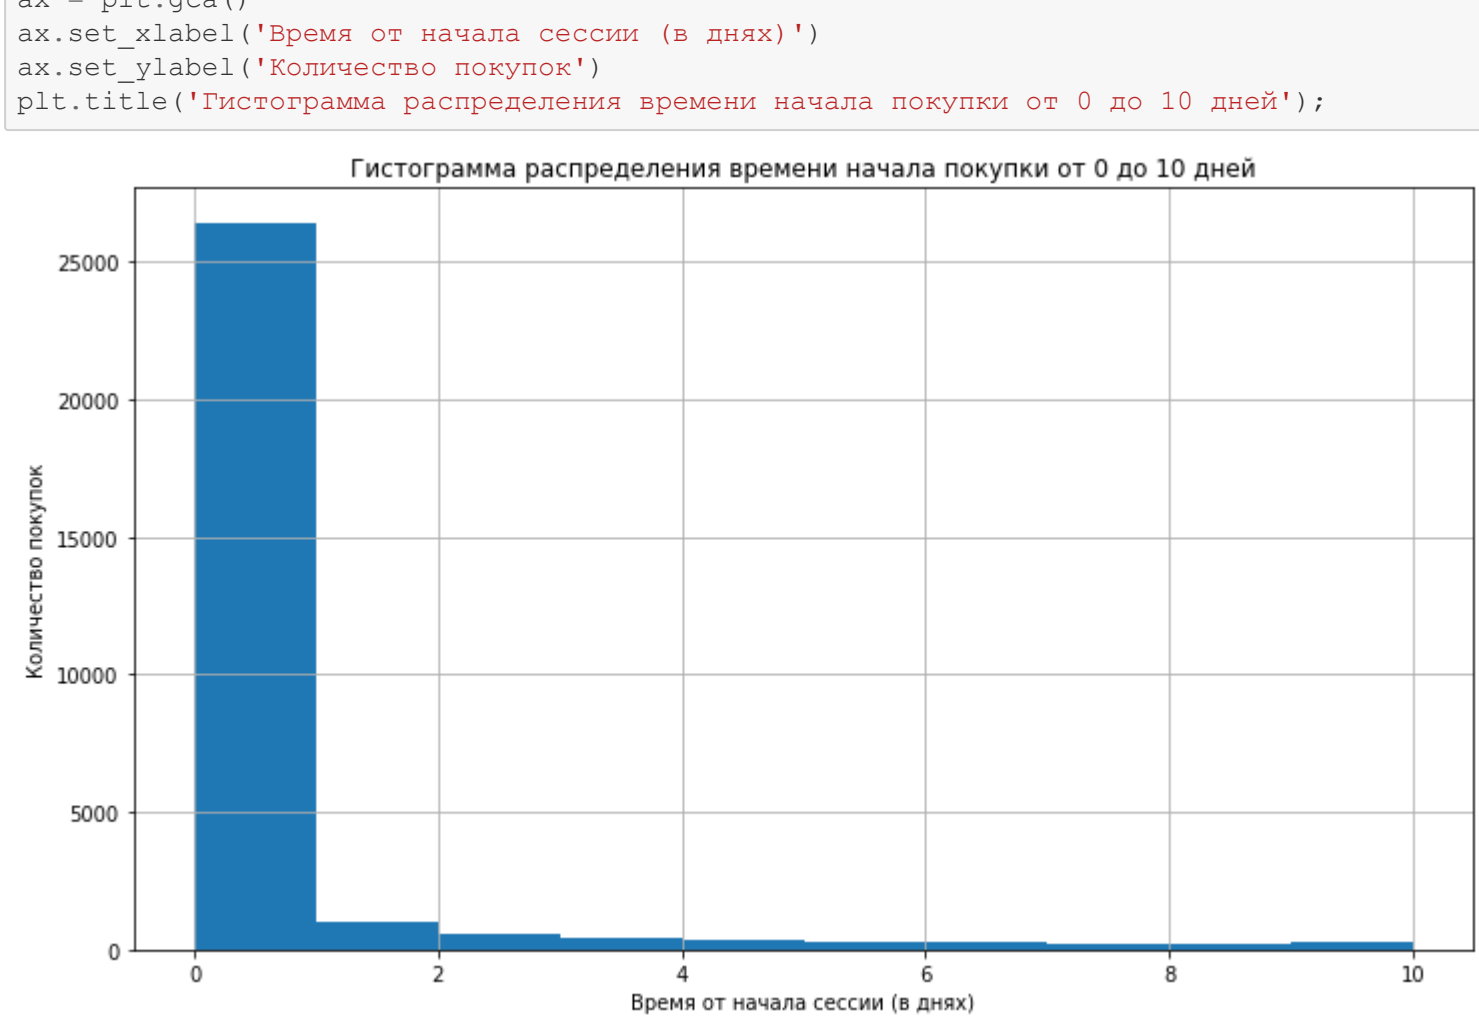

Вывод: люди покупают сразу.

- Посчитаем, сколько раз покупают за период. Добавим в таблицу `orders_log` столбцы *order_month* — месяц покупки и *first_order_month* — дата первой покупки.

```
In [46]: orders_log = orders_log.join(first_order_date_by_users,on='user_id')
orders_log['order_month'] = orders_log['order_ts'].astype('datetime64[M]')
orders_log['first_order_month'] = orders_log['first_order_month'].astype('datetime64[M]')
```

Построим сводную таблицу `user_order_pivot` методом `pivot_table()`:

- в строках *index* будет когорта пользователей *first_order_month*;
- в столбцах *columns* — месяц совершения покупки *order_month*;
- значениями *values* станет количество уникальных пользователей *user_id*;
- в аргументе *aggfunc* укажем *nunique*.

Выведем результат на экран.

```
In [47]: user_order_pivot = orders_log.pivot_table(
    index='first_order_month',
    columns='order_month',
    values='user_id',
    aggfunc='nunique')
user_order_pivot
```

Out[47]:

order_month / first_order_month	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01	2018-06-01
2017-06-01	2023.0	61.0	50.0	54.0	88.0	67.0	62.0	47.0	58.0	45.0	45.0	53.0	NaN
2017-07-01	NaN	1923.0	52.0	57.0	64.0	49.0	38.0	36.0	39.0	42.0	22.0	26.0	NaN
2017-08-01	NaN	NaN	1370.0	58.0	53.0	44.0	40.0	32.0	30.0	44.0	19.0	31.0	NaN
2017-09-01	NaN	NaN	NaN	2581.0	130.0	100.0	74.0	52.0	64.0	66.0	37.0	43.0	NaN
2017-10-01	NaN	NaN	NaN	NaN	4340.0	206.0	123.0	92.0	93.0	72.0	56.0	67.0	NaN
2017-11-01	NaN	NaN	NaN	NaN	NaN	4081.0	222.0	120.0	106.0	81.0	48.0	62.0	NaN
2017-12-01	NaN	NaN	NaN	NaN	NaN	NaN	4383.0	146.0	103.0	97.0	50.0	63.0	NaN
2018-01-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3373.0	114.0	83.0	43.0	45.0	NaN
2018-02-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3651.0	118.0	58.0	39.0	NaN
2018-03-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3533.0	90.0	58.0	NaN
2018-04-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2276.0	69.0	NaN
2018-05-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2988.0	NaN
2018-06-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	1.0

```
In [48]: user_order_pivot = orders_log[orders_log['order_month'] != '2018-06-01'].pivot_table(
    index='first_order_month',
    columns='order_month',
    values='user_id',
    aggfunc='nunique')
user_order_pivot
```

Out[48]:

order_month / first_order_month	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01
2017-06-01	2023.0	61.0	50.0	54.0	88.0	67.0	62.0	47.0	58.0	45.0	45.0	53.0
2017-07-01	NaN	1923.0	52.0	57.0	64.0	49.0	38.0	36.0	39.0	42.0	22.0	26.0
2017-08-01	NaN	NaN	1370.0	58.0	53.0	44.0	40.0	32.0	30.0	44.0	19.0	31.0
2017-09-01	NaN	NaN	NaN	2581.0	130.0	100.0	74.0	52.0	64.0	66.0	37.0	43.0
2017-10-01	NaN	NaN	NaN	NaN	4340.0	206.0	123.0	92.0	93.0	72.0	56.0	67.0
2017-11-01	NaN	NaN	NaN	NaN	NaN	4081.0	222.0	120.0	106.0	81.0	48.0	62.0
2017-12-01	NaN	NaN	NaN	NaN	NaN	NaN	4383.0	146.0	103.0	97.0	50.0	63.0
2018-01-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3373.0	114.0	83.0	43.0	45.0
2018-02-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3651.0	118.0	58.0	39.0
2018-03-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	3533.0	90.0	58.0
2018-04-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2276.0	69.0
2018-05-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2988.0

```
In [49]: plt.figure(figsize=(13, 9))
plt.title('Динамика покупок по времени жизни когорт')
sns.heatmap(user_order_pivot, cmap='Blues', annot=True, fmt='.2f', linewidths=1, linecolor='gray', vmin=0, vmax=250)
ax = plt.gca()
ax.set_xticklabels(user_order_pivot.columns.strftime('%Y-%m'))
ax.set_yticklabels(user_order_pivot.index.strftime('%Y-%m'))
ax.set_xlabel('Месяцы покупок')
ax.set_ylabel('Когорты пользователей');
```

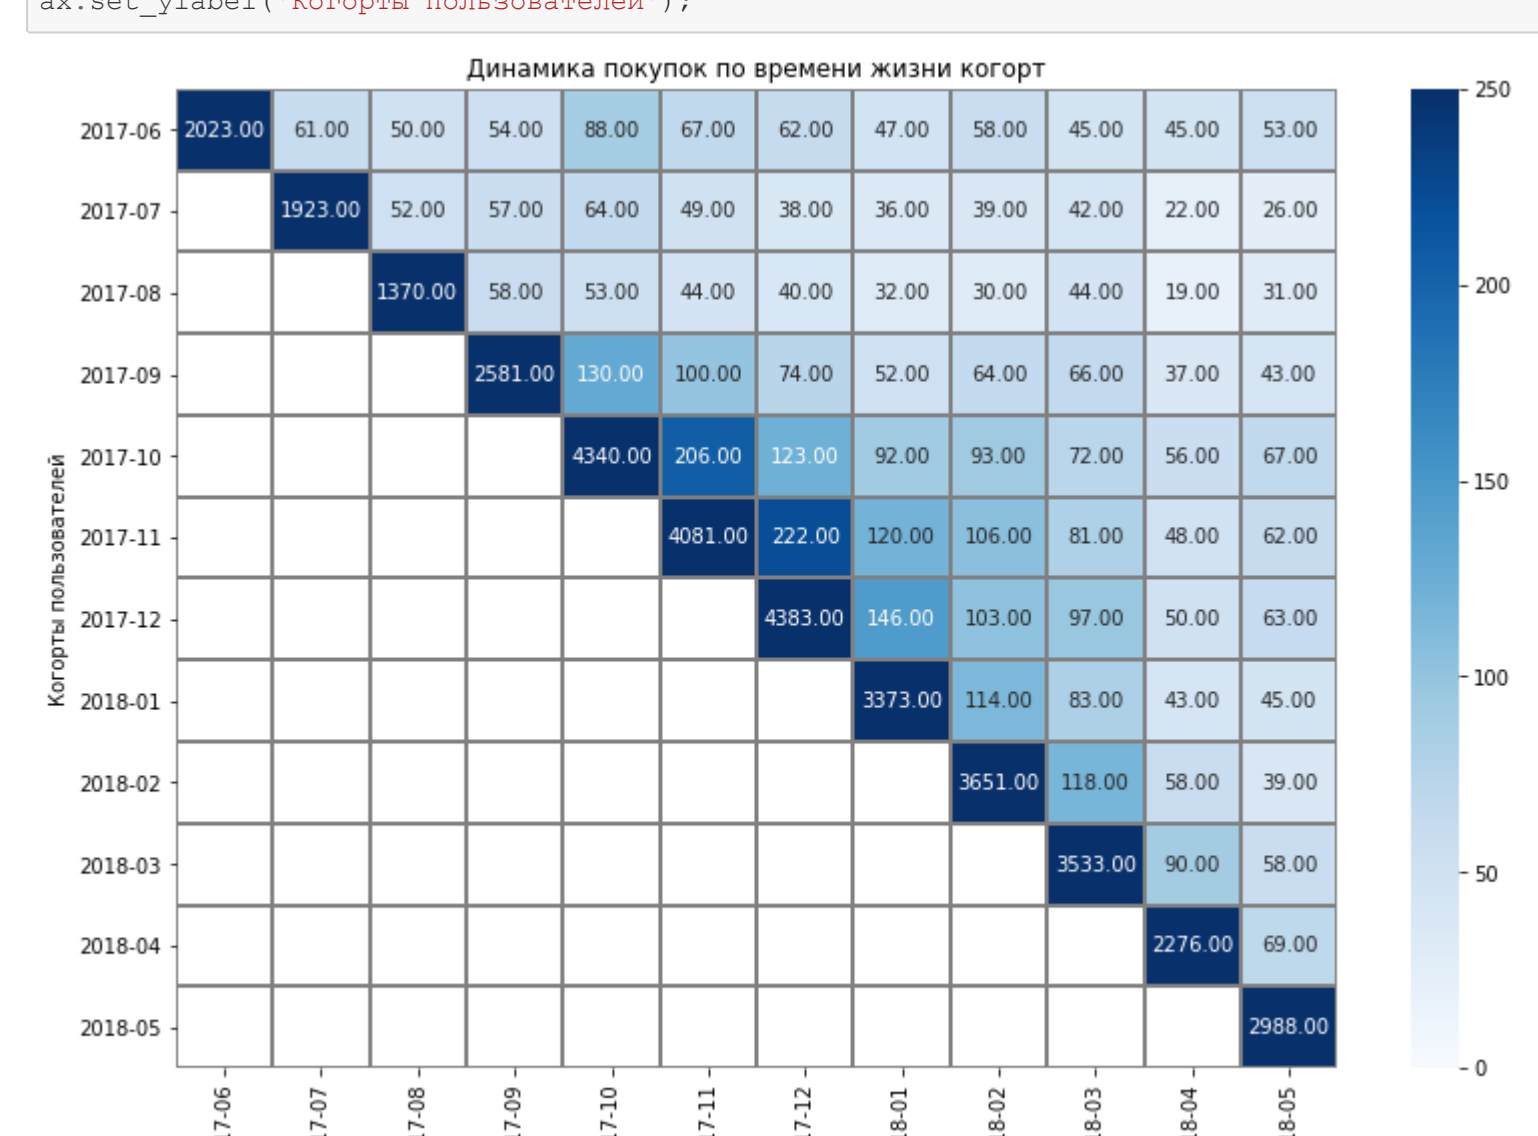

Вывод: после первого месяца количество покупателей в когорте резко снижается, ноябрьский всплеск на месте.

- Посчитаем средний чек. Для этого сгруппируем таблицу `orders_log` по когорте *first_order_month* и месяцу совершения заказа *order_month*, найдём суммарный чек и количество покупателей.

```
In [50]: orders_grouped_by_cohorts = orders_log.groupby(
    ['first_order_month','order_month']).agg({'revenue':'sum','user_id':'nunique'})
orders_grouped_by_cohorts.head()
```

Out[50]:

first_order_month	order_month	revenue	user_id
2017-06-01	2017-06-01	9557.49	2023
	2017-07-01	981.82	61
	2017-08-01	885.34	50
	2017-09-01	1931.30	54
	2017-10-01	2068.58	88

Найдём средний чек покупателя *revenue_per_user* — разделим показатель *revenue* на *user_id*:

```
In [51]: orders_grouped_by_cohorts['revenue_per_user'] = orders_grouped_by_cohorts['revenue'] / orders_grouped_by_cohorts['user_id']
```

Построим сводную таблицу изменения среднего чека в когортах по месяцу совершения покупки и оценим, как изменяется средний чек с течением времени.

```
In [52]: orders_grouped_by_cohorts.pivot_table(
    index='first_order_month',columns='order_month',values='revenue_per_user',aggfunc='mean')
```

Out[52]:

order_month / first_order_month	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01
2017-06-01	4.724414	16.095410	17.706800	35.764815	23.506591	22.207761	31.011935	25.033191	19.295690	27.233556	25.6813
2017-07-01	NaN	6.010218	12.396346	21.035965	10.786094	6.938163	7.896842	6.421111	6.992821	7.382143	12.8618
2017-08-01	NaN	NaN	5.276518	11.148793	11.851321	12.182955	16.921250	12.139063	9.620333	12.610455	21.0700
2017-09-01	NaN	NaN	NaN	5.644529	22.188385	13.445200	138.669189	19.881538	26.095000	27.437121	16.9613
2017-10-01	NaN	NaN	NaN	NaN	5.003733	11.287427	6.753252	7.413152	7.072796	7.255139	6.5732
2017-11-01	NaN	NaN	NaN	NaN	NaN	5.154683	7.339054	6.786583	12.510660	7.457284	4.5808
2017-12-01	NaN	NaN	NaN	NaN	NaN	NaN	4.738191	7.816575	39.366019	48.135052	27.4314
2018-01-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	4.135636	8.721228	12.365542	11.1997
2018-02-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	4.156987	8.610000	4.9424
2018-03-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	4.838803	11.8116
2018-04-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	4.6575
2018-05-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
2018-06-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na

Найдём, как изменяется средний чек в зависимости от времени, прошедшего с момента первой покупки. Из месяца совершения заказа *order_month* вычтем месяц когорты *first_order_month*, сохраним в столбец *cohort_lifetime*.

```
In [53]: orders_grouped_by_cohorts = orders_grouped_by_cohorts.reset_index()
orders_grouped_by_cohorts['cohort_lifetime'] = (
    orders_grouped_by_cohorts['order_month'] - orders_grouped_by_cohorts['first_order_month'])
```

Поделим *cohort_lifetime* на константу `np.timedelta64(1, 'M')`, чтобы узнать, сколько величин длиной в 1 месяц содержится в *cohort_lifetime*. Округлим значения столбца *cohort_lifetime* методом `round()`, а затем приведём их к целочисленному типу методом `astype('int')`.

```
In [54]: orders_grouped_by_cohorts['cohort_lifetime'] = orders_grouped_by_cohorts['cohort_lifetime'] / np.timedelta64(1,'M')
orders_grouped_by_cohorts['cohort_lifetime'] = orders_grouped_by_cohorts['cohort_lifetime'].round().astype('int')
```

Оставим в данных о месяце первого заказа только год и месяц, применив метод `dt.strftime()`.

```
In [55]: orders_grouped_by_cohorts['first_order_month'] = orders_grouped_by_cohorts['first_order_month'].dt.strftime('%Y-%m')
```

Построим сводную таблицу изменения среднего чека, где в столбцах будет *lifetime*, а строках — когорты. Выведем результат на экран.

```
In [56]: revenue_per_user_pivot = orders_grouped_by_cohorts.pivot_table(
    index='first_order_month',columns='cohort_lifetime',values='revenue_per_user',aggfunc='mean')
revenue_per_user_pivot
```

Out[56]:

cohort_lifetime / first_order_month	0	1	2	3	4	5	6	7	8	9	10
2017-06	4.724414	16.095410	17.706800	35.764815	23.506591	22.207761	31.011935	25.033191	19.295690	27.233556	25.6813
2017-07	6.010218	12.396346	21.035965	10.786094	6.938163	7.896842	6.421111	6.992821	7.382143	12.861818	11.5138
2017-08	5.276518	11.148793	11.851321	12.182955	16.921250	12.139063	9.620333	12.610455	21.070000	8.307419	Na
2017-09	5.644529	22.188385	13.445200	138.669189	19.881538	26.095000	27.437121	16.961351	11.044651	NaN	Na
2017-10	5.003733	11.287427	6.753252	7.413152	7.072796	7.255139	6.573214	7.479701	NaN	NaN	Na
2017-11	5.154683	7.339054	6.786583	12.510660	7.457284	4.580833	7.564839	NaN	NaN	NaN	Na
2017-12	4.738191	7.816575	39.366019	48.135052	27.431400	23.518413	NaN	NaN	NaN	NaN	Na
2018-01	4.135636	8.721228	12.365542	11.199767	4.699556	NaN	NaN	NaN	NaN	NaN	Na
2018-02	4.156987	8.610000	4.942414	6.941026	NaN	NaN	NaN	NaN	NaN	NaN	Na
2018-03	4.838803	11.811667	19.221897	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
2018-04	4.657597	17.535072	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
2018-05	4.660562	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
2018-06	3.420000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na

Построим тепловую карту.

```
In [57]: plt.figure(figsize=(13, 9))
plt.title('Изменение среднего чека по времени жизни когорт')
sns.heatmap(revenue_per_user_pivot, cmap='Blues', annot=True, fmt='.2f', linewidths=1, linecolor='gray', vmin=0, vmax=75)
ax = plt.gca()
ax.set_yticklabels(retention_pivot.index.strftime('%Y-%m'))
ax.set_xlabel('Месяцы посещений по счёту')
ax.set_ylabel('Когорты пользователей');
```

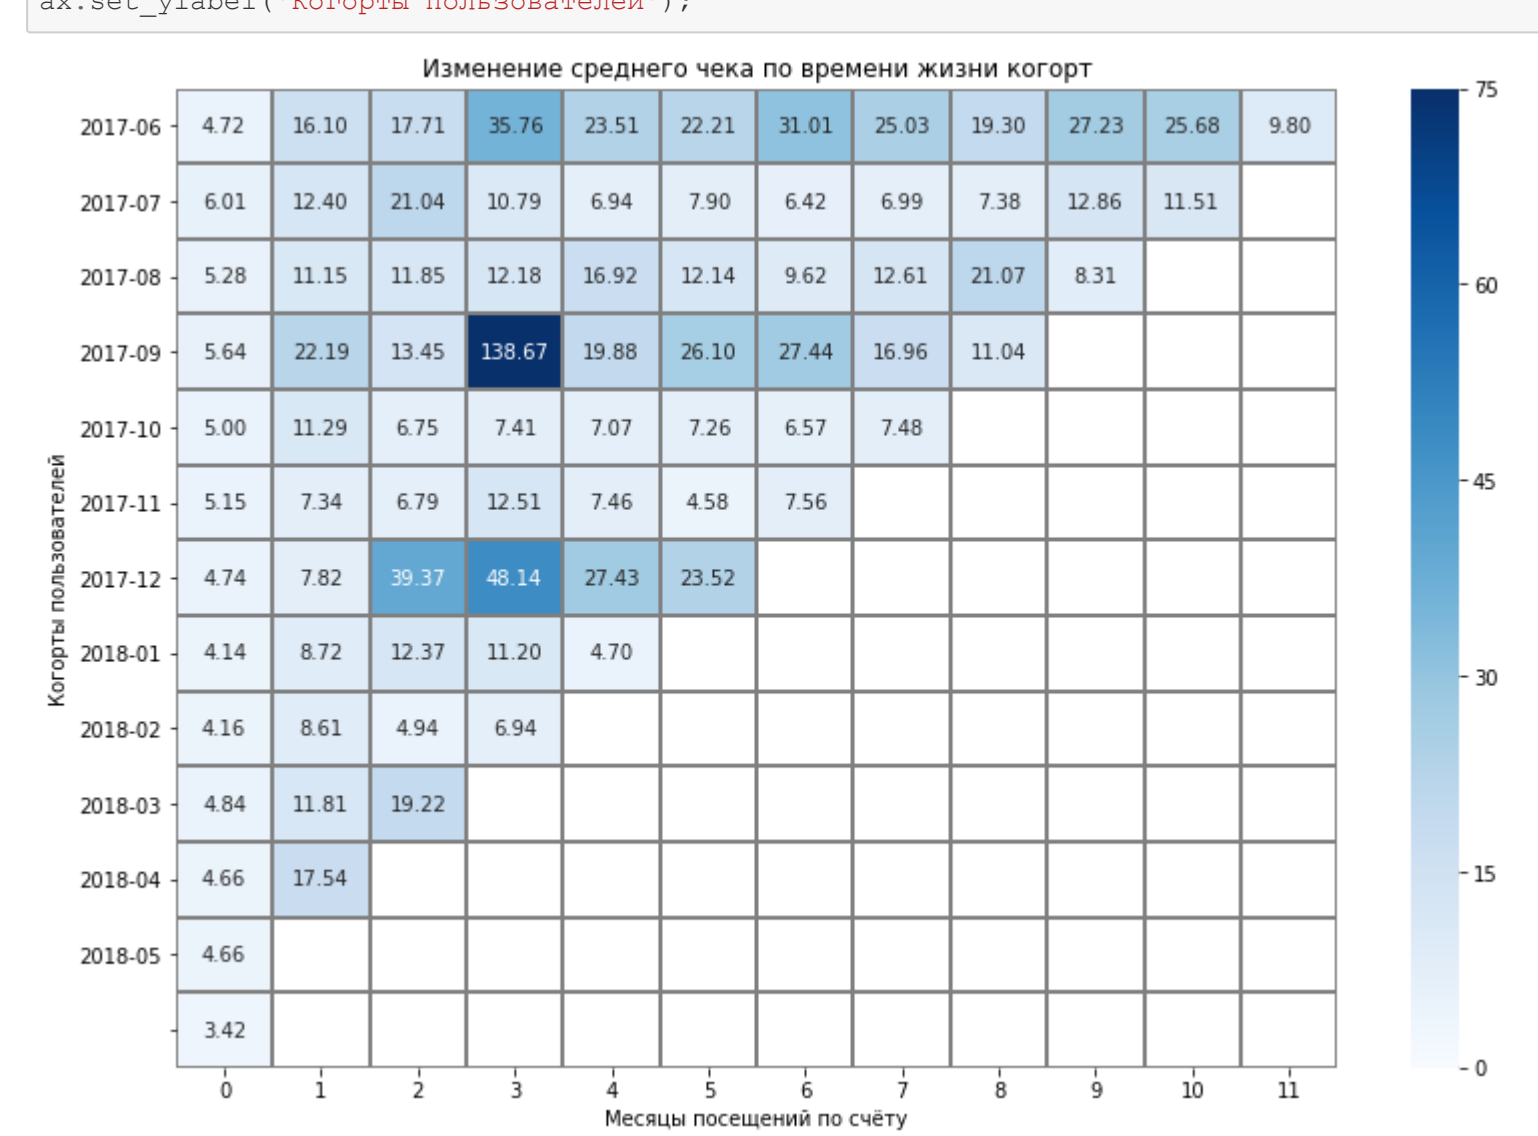

Вывод: у первых покупок минимальный чек: покупатели прицениваются.

- Посчитаем, сколько денег приносят пользователи (**LTV**).

Получим месяц первой покупки каждого покупателя.

```
In [58]: first_orders = orders_log.groupby('user_id').agg({'order_month': 'min'}).reset_index()
first_orders.columns = ['user_id', 'first_order_month']
first_orders.head()
```

Out[58]:

	user_id	first_order_month
0	313578113262317	2018-01-01
1	1575281904278712	2017-06-01
2	2429014661409475	2017-10-01
3	2464366381792757	2018-01-01
4	2551852515556206	2017-11-01

Посчитаем количество новых покупателей *n_buyers* за каждый месяц.

```
In [59]: cohort_sizes = first_orders.groupby('first_order_month').agg({'user_id': 'nunique'}).reset_index()
cohort_sizes.columns = ['first_order_month', 'n_buyers']
cohort_sizes
```

Out[59]:

	first_order_month	n_buyers
0	2017-06-01	2023
1	2017-07-01	1923
2	2017-08-01	1370
3	2017-09-01	2581
4	2017-10-01	4340
5	2017-11-01	4081
6	2017-12-01	4383
7	2018-01-01	3373
8	2018-02-01	3651
9	2018-03-01	3533
10	2018-04-01	2276
11	2018-05-01	2988
12	2018-06-01	1

Сгруппируем таблицу заказов по месяцу первой покупки и месяцу каждого заказа и сложим выручку. Сбросим индекс методом `reset_index()`.

```
In [60]: cohorts = orders_log.groupby(['first_order_month','order_month']).agg({'revenue': 'sum'}).reset_index()
cohorts
```

Out[60]:

	first_order_month	order_month	revenue
0	2017-06-01	2017-06-01	9557.49
1	2017-06-01	2017-07-01	981.82
2	2017-06-01	2017-08-01	885.34
3	2017-06-01	2017-09-01	1931.30
4	2017-06-01	2017-10-01	2068.58
...	...	...	...
74	2018-03-01	2018-05-01	1114.87
75	2018-04-01	2018-04-01	10600.69
76	2018-04-01	2018-05-01	1209.92
77	2018-05-01	2018-05-01	13925.76
78	2018-06-01	2018-06-01	3.42

79 rows × 3 columns

Добавим в таблицу `cohorts` данные о том, сколько людей первый раз совершили покупку в каждый месяц.

```
In [61]: report = pd.merge(cohort_sizes, cohorts, on='first_order_month')
report
```

Out[61]:

	first_order_month	n_buyers	order_month	revenue
0	2017-06-01	2023	2017-06-01	9557.49
1	2017-06-01	2023	2017-07-01	981.82
2	2017-06-01	2023	2017-08-01	885.34
3	2017-06-01	2023	2017-09-01	1931.30
4	2017-06-01	2023	2017-10-01	2068.58
...	...	...	...	...
74	2018-03-01	3533	2018-05-01	1114.87
75	2018-04-01	2276	2018-04-01	10600.69
76	2018-04-01	2276	2018-05-01	1209.92
77	2018-05-01	2988	2018-05-01	13925.76
78	2018-06-01	1	2018-06-01	3.42

79 rows × 4 columns

Добавим возраст (*age*) когорты.

```
In [62]: report['age'] = (report['order_month'] - report['first_order_month']) / np.timedelta64(1, 'M')
report['age'] = report['age'].round().astype('int')
report.head()
```

Out[62]:

	first_order_month	n_buyers	order_month	revenue	age
0	2017-06-01	2023	2017-06-01	9557.49	0
1	2017-06-01	2023	2017-07-01	981.82	1
2	2017-06-01	2023	2017-08-01	885.34	2
3	2017-06-01	2023	2017-09-01	1931.30	3
4	2017-06-01	2023	2017-10-01	2068.58	4

Найдём **LTV**, разделив валовую прибыль когорт за каждый месяц на общее число пользователей в каждой когорте. Построим сводную таблицу.

```
In [63]: margin_rate = 1

report['ltv'] = margin_rate * report['revenue'] / report['n_buyers']

output = report.pivot_table(
        index='first_order_month',
        columns='age',
        values='ltv',
        aggfunc='mean')

output.fillna('')
```

Out[63]:

age / first_order_month	0	1	2	3	4	5	6	7	8	9	10	11
2017-06-01	4.724414	0.485329	0.437637	0.954671	1.02253	0.735502	0.95044	0.581592	0.553213	0.605788	0.571261	0.2
2017-07-01	6.010218	0.335211	0.623531	0.358976	0.176791	0.156048	0.120208	0.14182	0.161232	0.147145	0.155673	
2017-08-01	5.276518	0.471993	0.458482	0.391277	0.494051	0.28354	0.210664	0.405007	0.292212	0.187978		
2017-09-01	5.644529	1.11759	0.52093	3.97579	0.400558	0.647067	0.701608	0.24315	0.184006			
2017-10-01	5.003733	0.535763	0.191394	0.157145	0.15156	0.120362	0.0848157	0.11547				
2017-11-01	5.154683	0.399233	0.199556	0.324952	0.148013	0.053879	0.114928					
2017-12-01	4.738191	0.260374	0.925097	1.06527	0.31293	0.338047						
2018-01-01	4.135636	0.294758	0.304281	0.142778	0.0626979							
2018-02-01	4.156987	0.278274	0.0785155	0.0741441								
2018-03-01	4.838803	0.300892	0.315559									
2018-04-01	4.657597	0.531599										
2018-05-01	4.660562											
2018-06-01	3.420000											

```
In [64]: plt.figure(figsize=(13, 9))
plt.title('Изменение средней суммы денег по времени жизни когорт')
sns.heatmap(output.cumsum(axis=1), cmap='Blues', annot=True, fmt='.2f', linewidths=1, linecolor='gray')
 #, vmin=0, vmax=75)
ax = plt.gca()
ax.set_yticklabels(output.cumsum(axis=1).index.strftime('%Y-%m'))
ax.set_xlabel('Время жизни когорт')
ax.set_ylabel('Когорты пользователей');
```

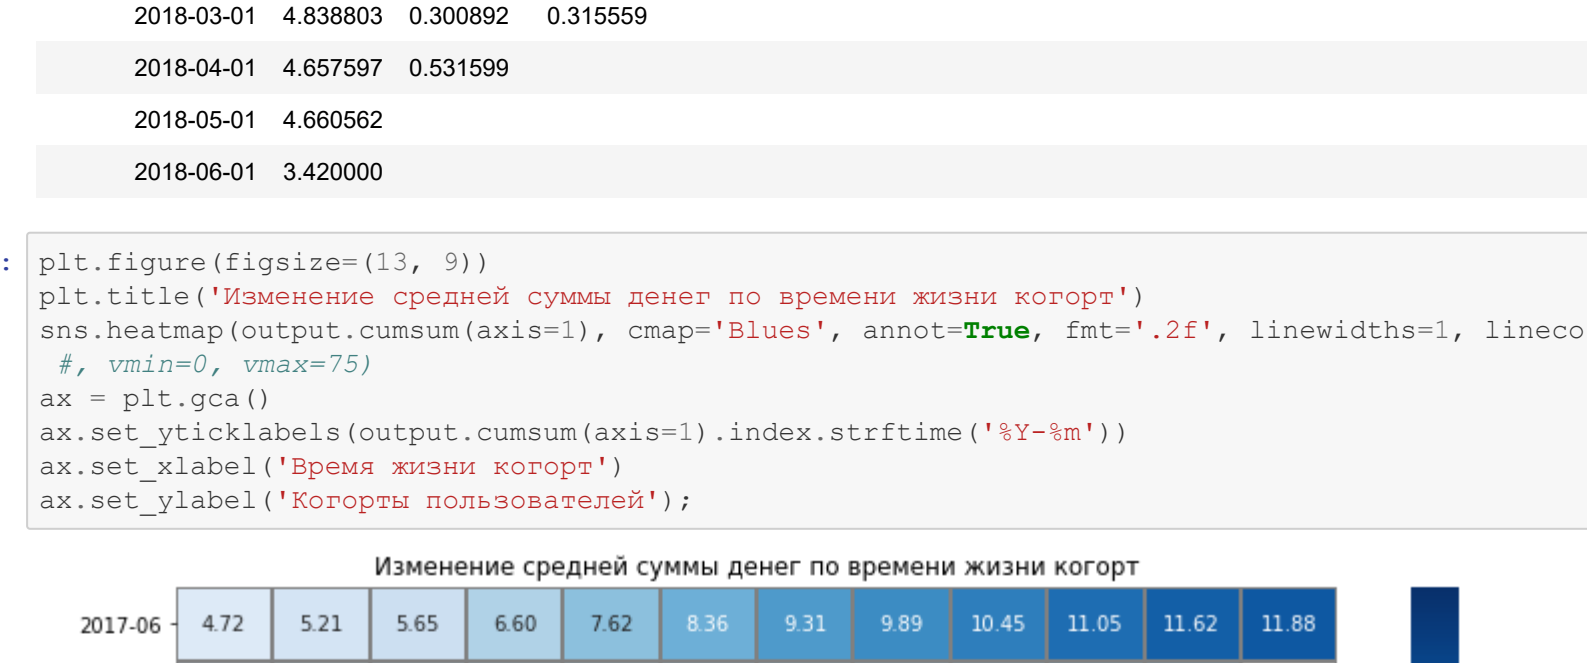

Посчитаем **LTV** каждой когорты. Сложим **LTV** по месяцам.

```
In [65]: LTV = output.sum(axis=1).reset_index()
LTV.columns = ['first_order_month', 'LTV']
LTV
```

Out[65]:

	first_order_month	LTV
0	2017-06-01	11.879234
1	2017-07-01	8.386854
2	2017-08-01	8.471723
3	2017-09-01	13.435227
4	2017-10-01	6.360242
5	2017-11-01	6.395244
6	2017-12-01	7.639913
7	2018-01-01	4.940151
8	2018-02-01	4.587921
9	2018-03-01	5.455253
10	2018-04-01	5.189196
11	2018-05-01	4.660562
12	2018-06-01	3.420000

В среднем каждый покупатель из первой когорты принес меньше 12 рублей выручки за год «жизни».

Сразу посчитаем **CAC** (*customer acquisition cost*) — стоимость привлечения клиента. Для этого найдём месяц каждой затраты и сгруппируем по месяцам.

```
In [66]: costs['order_month'] = costs['dt'].astype('datetime64[M]')
monthly_costs = costs.groupby(['order_month']).agg({'costs':'sum'})
monthly_costs
```

Out[66]:

order_month	costs
2017-06-01	18015.00
2017-07-01	18240.59
2017-08-01	14790.54
2017-09-01	24368.91
2017-10-01	36322.88
2017-11-01	37907.88
2017-12-01	38315.35
2018-01-01	33518.52
2018-02-01	32723.03
2018-03-01	30415.27
2018-04-01	22289.38
2018-05-01	22224.27

Посчитаем **CAC** каждой когорты. Поделим расходы за каждый месяц на количество людей в когорте.

```
In [67]: CAC = monthly_costs.reset_index()['costs'] / cohort_sizes['n_buyers']
CAC
```

```
Out[67]: 0      8.905091
1      9.485486
2     10.796015
3      9.441654
4      8.369327
5      9.288870
6      8.741809
7      9.937302
8      8.962758
9      8.608907
10     9.793225
11     7.437841
12          NaN
dtype: float64
```

LTV июньской когорты составляет меньше 12 рублей, **CAC** — меньше 9. Привлечение одного покупателя в среднем обошлось компании в 9 рублей. Валовая прибыль с каждого из них: 12 рублей. Вложения в привлечение покупателей окупились.

Маркетинг

Посчитаем, сколько денег потратили. Всего:

```
In [68]: costs['costs'].sum()
Out[68]: 329131.62
```

На каждый источник:

```
In [69]: costs_per_source = costs.groupby('source_id').sum()
costs_per_source
```

Out[69]:

source_id	costs
1	20833.27
2	42806.04
3	141321.63
4	61073.60
5	51757.10
9	5517.49
10	5822.49

```
In [70]: plt.figure(figsize=(12, 12))
plt.pie(costs.groupby('source_id').sum())
plt.legend(labels = costs.groupby('source_id').sum().index)
plt.title('Затраты по рекламным источникам');

/opt/conda/lib/python3.7/site-packages/ipykernel_launcher.py:2: MatplotlibDeprecationWarning: Non-1D inputs to pie() are currently squeeze()d, but this behavior is deprecated since 3.1 and will be removed in 3.3; pass a 1D array instead.
```

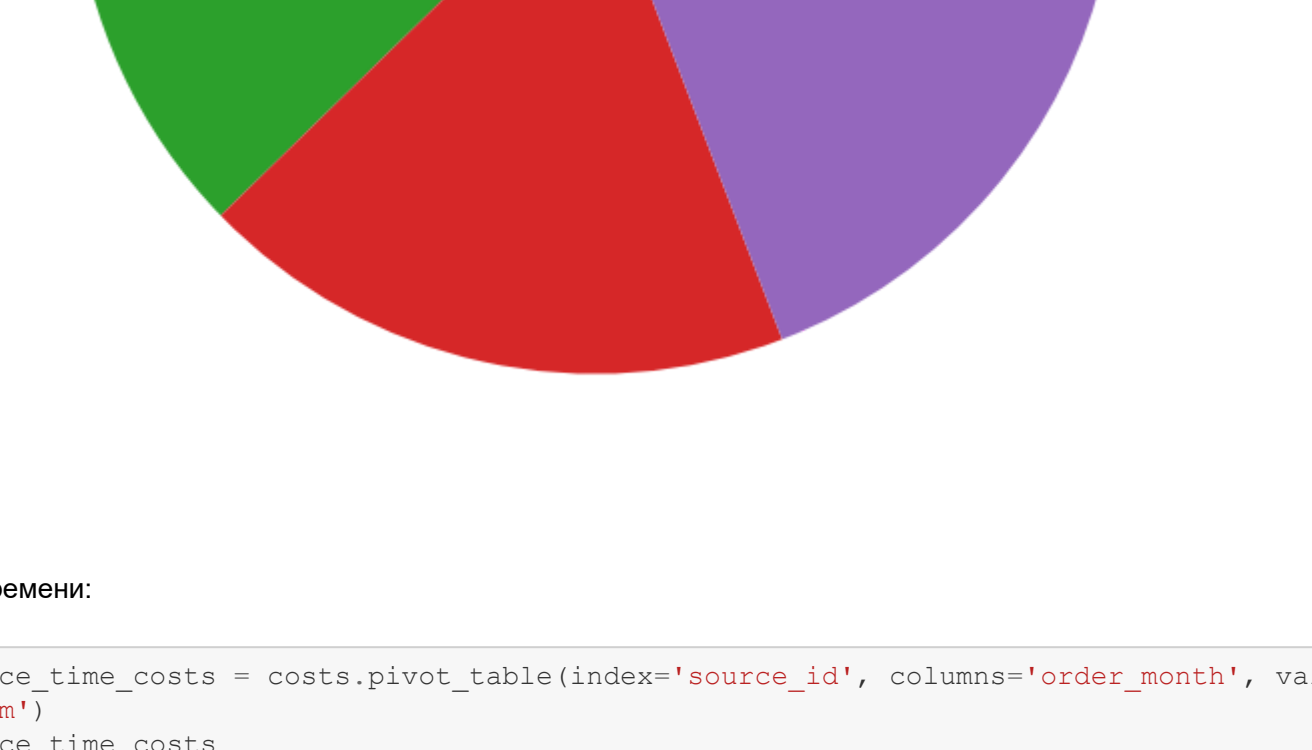

По времени:

```
In [71]: source_time_costs = costs.pivot_table(index='source_id', columns='order_month', values='costs', aggfunc='sum')
source_time_costs
```

Out[71]:

order_month / source_id	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01
1	1125.61	1072.88	951.81	1502.01	2315.75	2445.16	2341.20	2186.18	2204.48	1893.09	1327.49	1467.61
2	2427.38	2333.11	1811.05	2985.66	4845.00	5247.68	4897.80	4157.74	4474.34	3943.14	2993.70	2689.44
3	7731.65	7674.37	6143.54	9963.55	15737.24	17025.34	16219.52	14808.78	14228.56	13080.85	9296.81	9411.42
4	3514.80	3529.73	3217.36	5192.26	6420.84	5388.82	7680.47	5832.79	5711.96	5961.87	4408.49	4214.21
5	2616.12	2998.14	2185.28	3849.14	5767.40	6325.34	5872.52	5371.52	5071.31	4529.62	3501.15	3669.56
9	285.22	302.54	248.93	415.62	609.41	683.18	657.98	547.16	551.50	480.29	373.49	362.17
10	314.22	329.82	232.57	460.67	627.24	792.36	645.86	614.35	480.88	526.41	388.25	409.86

```
In [72]: plt.figure(figsize=(12, 7))
plt.title('Расходы на каждый рекламный источник по времени')
for i in source_time_costs.index:
    source_time_costs.loc[i, :].plot(x='order_month', label = i)
plt.legend()
plt.grid(True)
ax = plt.gca()
ax.grid(which='minor')
ax.set_xlabel('Месяцы затрат')
ax.set_ylabel('Суммарные затраты');
```

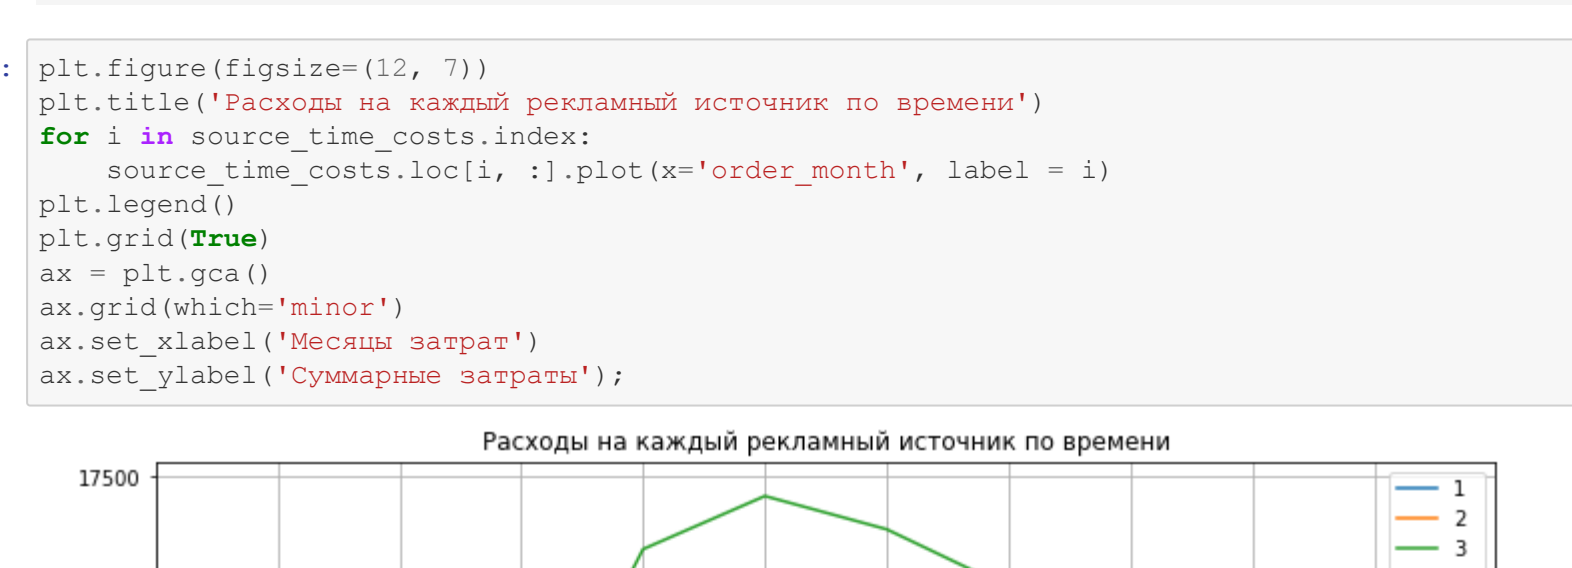

Вывод: наибольшие затраты на рекламный источник № 3. Пиковые расходы на него совпадают с пиком посещений пользователей.

Посчитаем сколько стоило привлечение одного покупателя из каждого источника. Сгруппируем количество уникальных посетителей по каждому источнику.

```
In [73]: visits_per_source = visits_log.groupby(['source_id']).agg({'user_id':'nunique'})
visits_per_source
```

Out[73]:

source_id	user_id
1	18999
2	26245
3	74756
4	83525
5	56974
6	6
7	34
9	9264
10	8067

Объединим данные по затратам на каждый источник с количеством уникальных пользователей по каждому источнику.

```
In [74]: costs_per_source = costs_per_source.merge(visits_per_source,on='source_id')
costs_per_source
```

Out[74]:

source_id	costs	user_id
1	20833.27	18999
2	42806.04	26245
3	141321.63	74756
4	61073.60	83525
5	51757.10	56974
9	5517.49	9264
10	5822.49	8067

```
In [75]: costs_per_source['costs_per_user'] = costs_per_source['costs'] / costs_per_source['user_id']
costs_per_source = costs_per_source.sort_values(by='costs_per_user', ascending=False)
costs_per_source
```

Out[75]:

source_id	costs	user_id	costs_per_user
3	141321.63	74756	1.890439
2	42806.04	26245	1.631017
1	20833.27	18999	1.096546
5	51757.10	56974	0.908434
4	61073.60	83525	0.731201
10	5822.49	8067	0.721766
9	5517.49	9264	0.595584

```
In [76]: costs_per_source_bar = costs_per_source['costs_per_user'].reset_index().sort_values(by='costs_per_user'
         , ascending=False)
```

```
In [77]: plt.figure(figsize=(12, 7))
         plt.bar(costs_per_source_bar['source_id'], costs_per_source_bar['costs_per_user'])
         ax = plt.gca()
         ax.set_xticks(costs_per_source_bar['source_id'])
         ax.set_xlabel('Месяцы покупок')
         ax.set_ylabel('Рекламные источники')
         plt.title('Гистограмма затрат на каждый источник с количеством уникальных пользователей по каждому исто
         чнику');
```

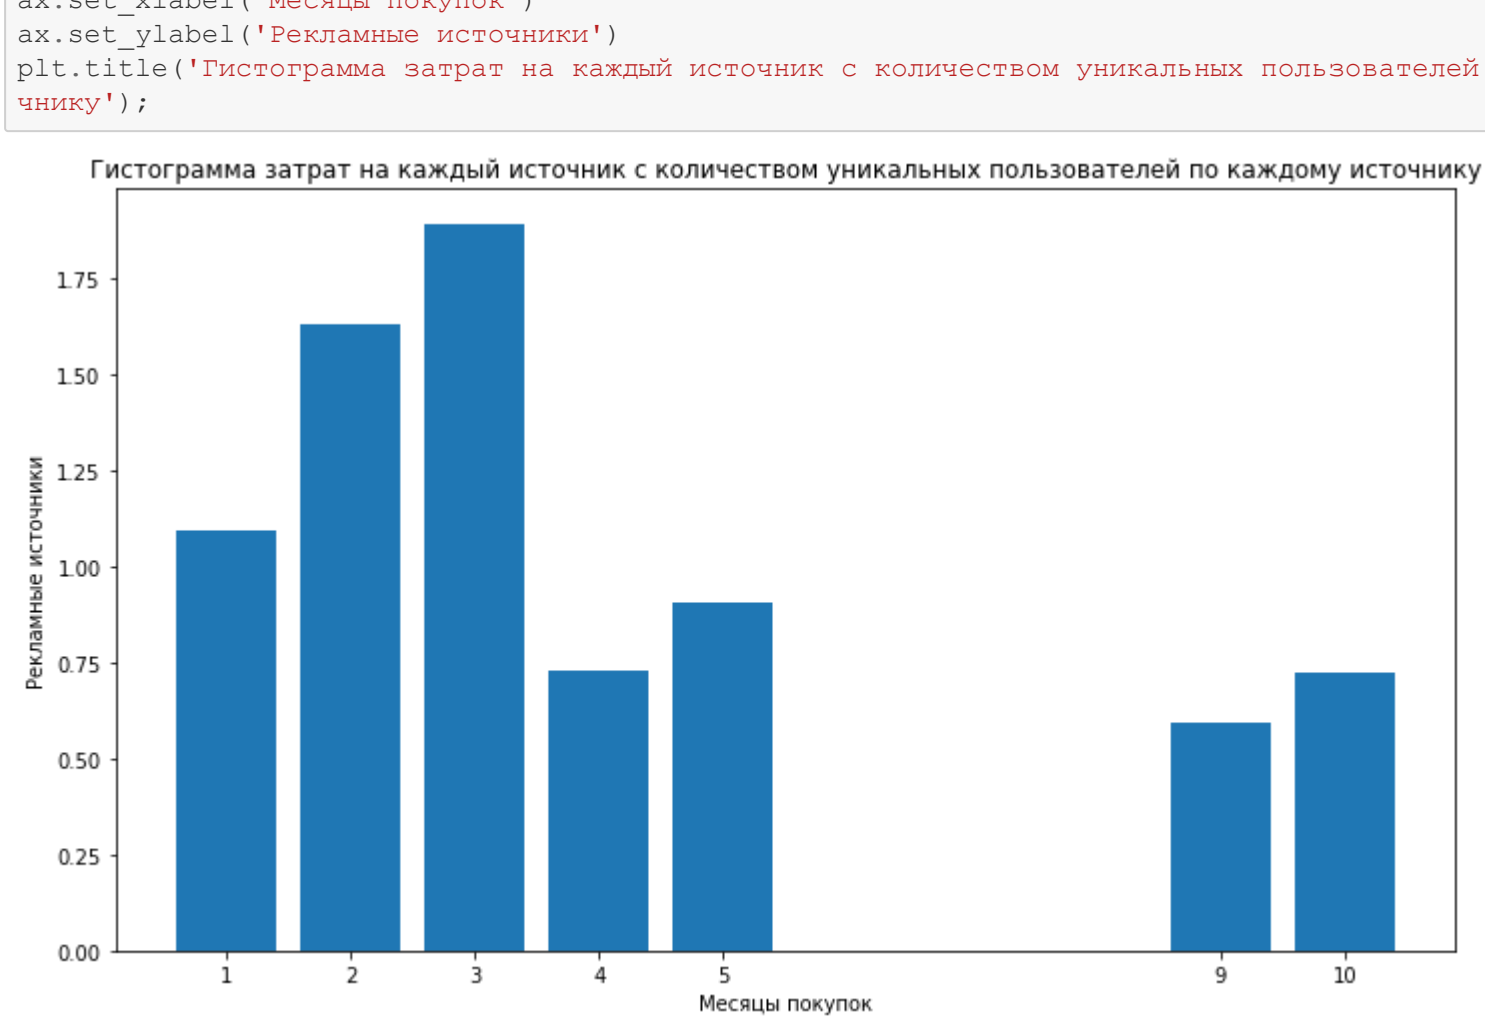

Вывод: самым затратным с точки зрения привлечения покупателя является рекламный источник № 3.

Посчитаем, насколько окупились расходы (**ROI** — *return on investments*). Чтобы не путать окупаемость бизнеса с окупаемостью маркетинга, вместо **ROI** рассчитывают **ROMI** (*return on marketing investments*).

Добавим данные о расходах в отчёт и посчитаем **CAC**.

```
In [78]: report_new = pd.merge(report, monthly_costs, left_on='first_order_month', right_on='order_month')
         report_new['cac'] = report_new['costs'] / report_new['n_buyers']
         report_new.head()
```

Out[78]:

	first_order_month	n_buyers	order_month	revenue	age	ltv	costs	cac
0	2017-06-01	2023	2017-06-01	9557.49	0	4.724414	18015.0	8.905091
1	2017-06-01	2023	2017-07-01	981.82	1	0.485329	18015.0	8.905091
2	2017-06-01	2023	2017-08-01	885.34	2	0.437637	18015.0	8.905091
3	2017-06-01	2023	2017-09-01	1931.30	3	0.954671	18015.0	8.905091
4	2017-06-01	2023	2017-10-01	2068.58	4	1.022531	18015.0	8.905091

Для расчёта **ROMI** поделим **LTV** на **CAC**. Построим сводную таблицу и посчитаем накопительный **ROMI** при помощи метода `cumsum()`.

```
In [79]: report_new['romi'] = report_new['ltv'] / report_new['cac']
         output_new = report_new.pivot_table(
                 index='first_order_month',
                 columns='age',
                 values='romi',
                 aggfunc='mean')
         output_new.cumsum(axis=1).round(2)
```

Out[79]:

age first_order_month	0	1	2	3	4	5	6	7	8	9	10	11
2017-06-01	0.53	0.59	0.63	0.74	0.86	0.94	1.05	1.11	1.17	1.24	1.31	1.33
2017-07-01	0.63	0.67	0.73	0.77	0.79	0.81	0.82	0.84	0.85	0.87	0.88	NaN
2017-08-01	0.49	0.53	0.57	0.61	0.66	0.68	0.70	0.74	0.77	0.78	NaN	NaN
2017-09-01	0.60	0.72	0.77	1.19	1.23	1.30	1.38	1.40	1.42	NaN	NaN	NaN
2017-10-01	0.60	0.66	0.68	0.70	0.72	0.74	0.75	0.76	NaN	NaN	NaN	NaN
2017-11-01	0.55	0.60	0.62	0.65	0.67	0.68	0.69	NaN	NaN	NaN	NaN	NaN
2017-12-01	0.54	0.57	0.68	0.80	0.84	0.87	NaN	NaN	NaN	NaN	NaN	NaN
2018-01-01	0.42	0.45	0.48	0.49	0.50	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-02-01	0.46	0.49	0.50	0.51	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-03-01	0.56	0.60	0.63	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-04-01	0.48	0.53	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2018-05-01	0.63	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

```
In [80]: plt.figure(figsize=(13, 9))
         plt.title('Накопительный ROMI по времени жизни когорт')
         sns.heatmap(output_new.cumsum(axis=1).round(2), cmap='Blues', annot=True, fmt='.0%', linewidths=1, line
         color='gray')
         ax = plt.gca()
         ax.set_yticklabels(output_new.cumsum(axis=1).round(2).index.strftime('%Y-%m'))
         ax.set_xlabel('Время жизни когорт')
         ax.set_ylabel('Когорты пользователей');
```

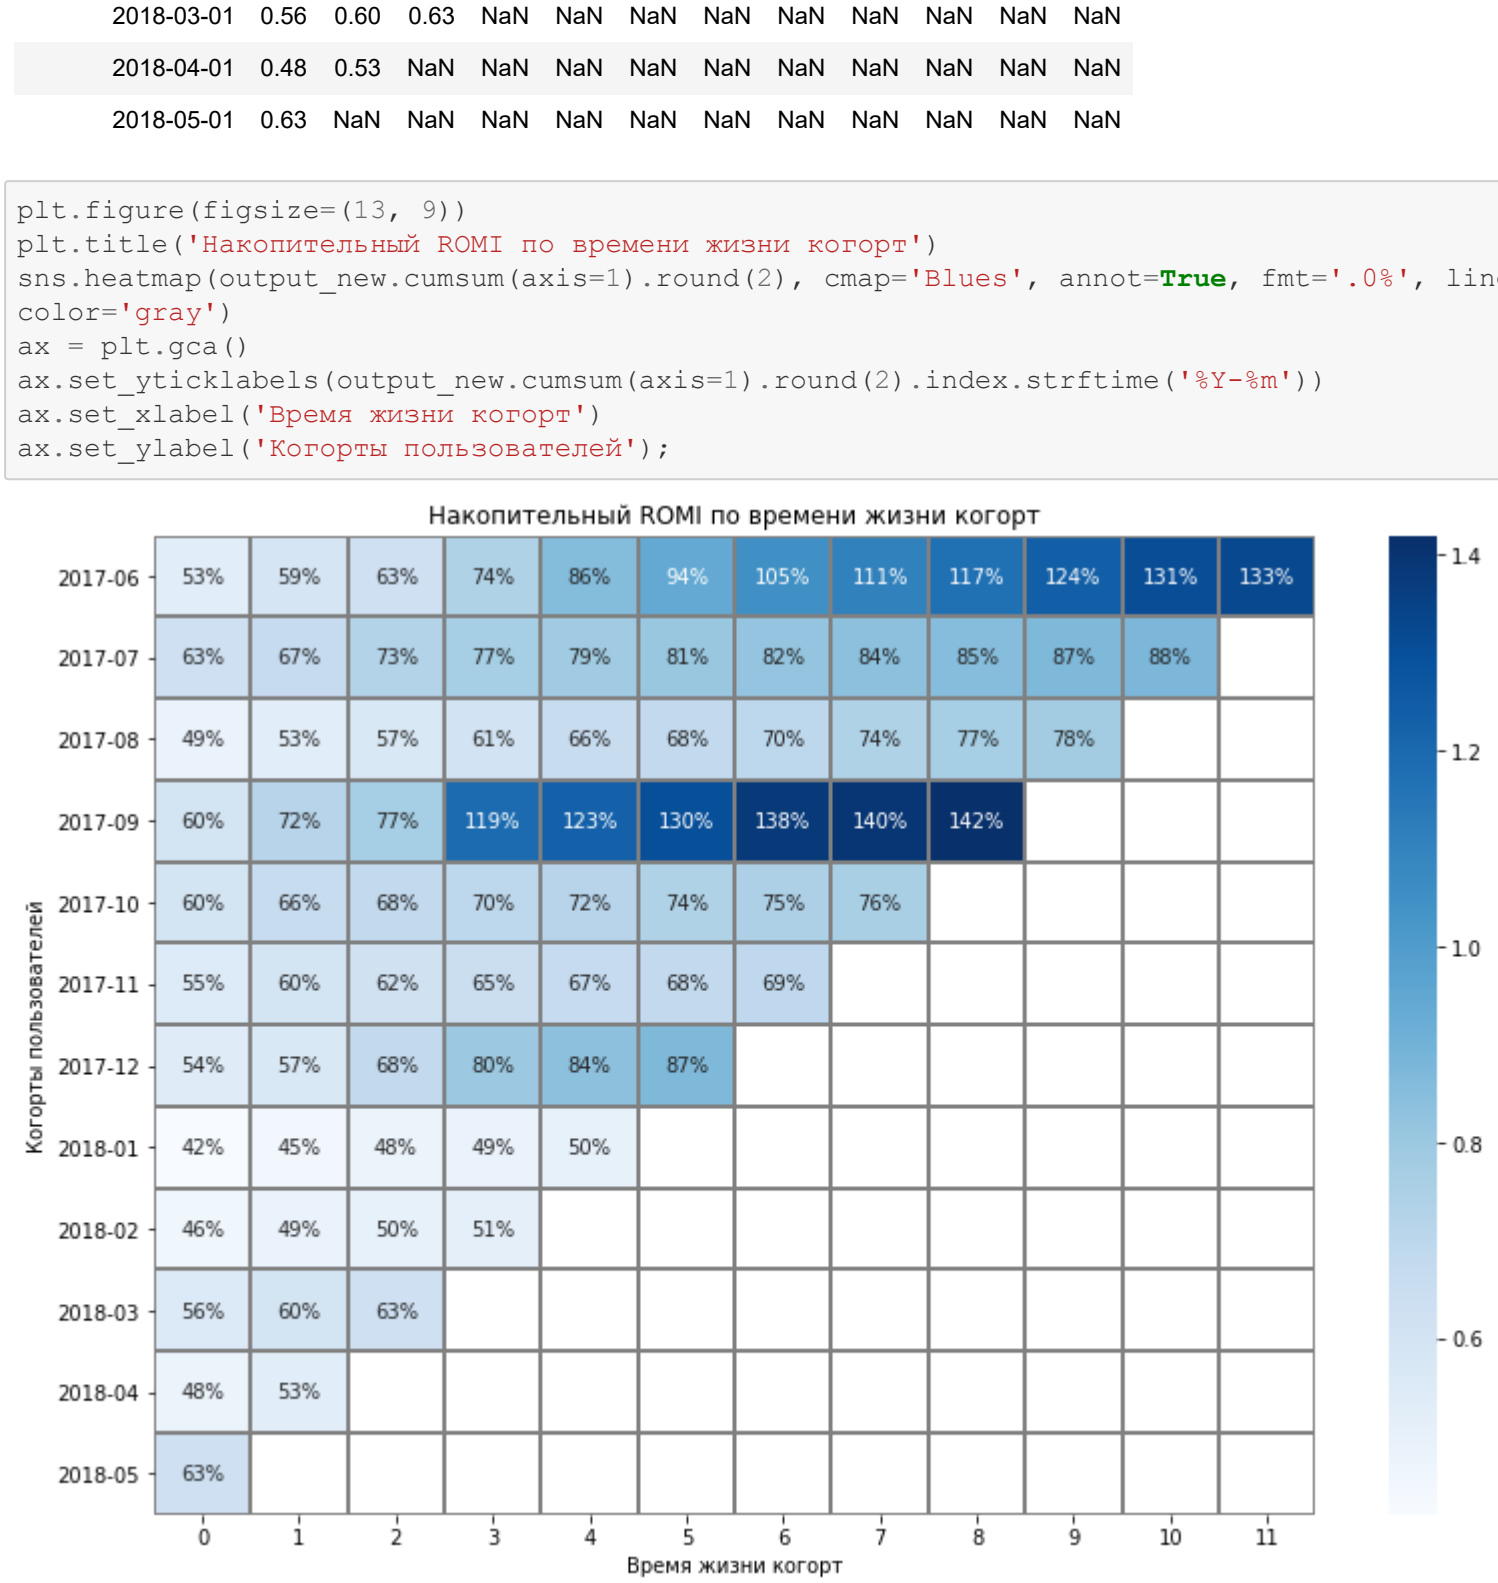

Посчитаем среднюю когорту.

```
In [81]: output_new.cumsum(axis=1).mean(axis=0)
```

```
Out[81]: age
         0     0.540816
         1     0.581985
         2     0.631069
         3     0.719740
         4     0.782946
         5     0.859876
         6     0.896819
         7     0.969951
         8     1.053871
         9     0.964488
         10    1.094658
         11    1.333982
         dtype: float64
```

Вывод: пока окупились только две когорты: июньская — за 7 месяцев и сентябрьская — за 4 месяца. Остальным для окупаемости требуется в среднем 8-10 месяцев.

Посчитаем, как менялось количество посещений с разных устройств по когортам.

```
In [82]: visits_per_device = visits_log.pivot_table(
             index='device', columns='first_visit_date', values='user_id', aggfunc='nunique')
         visits_per_device
```

Out[82]:

first_visit_date device	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01
desktop	10127	9610	7635	12006	18787	20439	18653	15976	15700	14474	10864	10252
touch	4106	4354	3015	5488	8299	7862	7392	7216	6967	6460	5033	5153

Построим график.

```
In [83]: plt.figure(figsize=(12, 7))
         plt.title('Посещения с каждой категории устройства по времени')
         for i in visits_per_device.index:
             visits_per_device.loc[i, :].plot(x='first_visit_date', label = i)
         plt.legend()
         plt.grid(True)
         ax = plt.gca()
         ax.grid(which='minor')
         ax.set_xlabel('Месяцы посещений')
         ax.set_ylabel('Количество посещений');
```

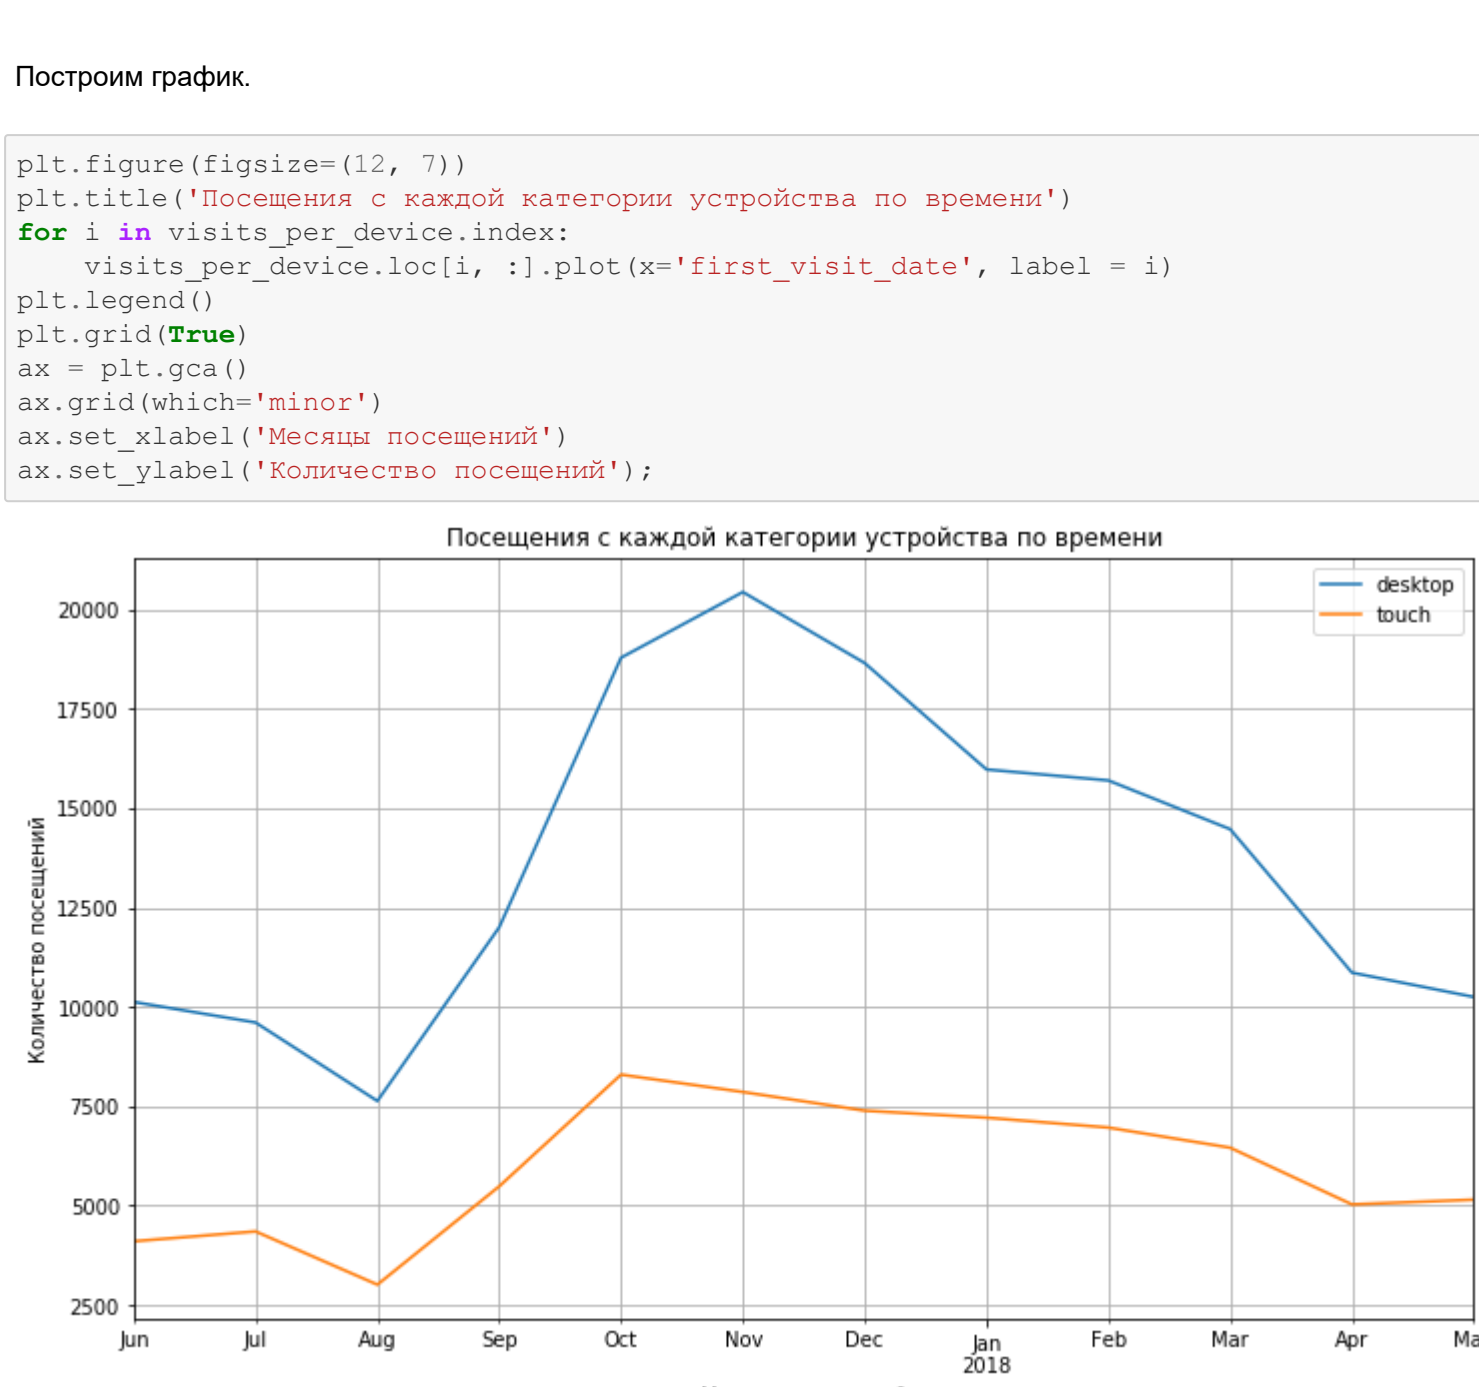

Посчитаем, как менялось количество посещений из разных рекламных источников по когортам.

```
In [84]: visits_per_sources = visits_log.pivot_table(
             index='source_id', columns='first_visit_date', values='user_id', aggfunc='nunique')
         visits_per_sources
```

Out[84]:

first_visit_date source_id	2017-06-01	2017-07-01	2017-08-01	2017-09-01	2017-10-01	2017-11-01	2017-12-01	2018-01-01	2018-02-01	2018-03-01	2018-04-01	2018-05-01
1	1513.0	1282.0	910.0	1526.0	2239.0	2484.0	2120.0	1647.0	1553.0	1515.0	1112.0	1098.0
2	2202.0	1974.0	1263.0	2114.0	3105.0	3426.0	2623.0	2171.0	2086.0	2059.0	1472.0	1750.0
3	5199.0	4582.0	3593.0	5981.0	8551.0	9572.0	8244.0	7385.0	7292.0	6136.0	4249.0	3972.0
4	4602.0	4644.0	3440.0	5721.0	9414.0	10272.0	10099.0	8599.0	7883.0	7730.0	5647.0	5474.0
5	3566.0	4005.0	3249.0	5093.0	7587.0	6351.0	5632.0	5226.0	5084.0	3926.0	4086.0	3169.0
6	1.0	1.0	1.0	NaN	NaN	1.0	1.0	1.0	NaN	NaN	NaN	NaN
7	2.0	2.0	2.0	2.0	6.0	1.0	9.0	4.0	2.0	1.0	1.0	2.0
9	1057.0	713.0	602.0	820.0	1039.0	1227.0	926.0	690.0	609.0	917.0	331.0	333.0
10	543.0	394.0	285.0	562.0	970.0	837.0	581.0	839.0	933.0	1003.0	492.0	628.0

Построим график.

```
In [85]: plt.figure(figsize=(12, 7))
         plt.title('Посещения на каждый рекламный источник по времени')
         for i in visits_per_sources.index:
             visits_per_sources.loc[i, :].plot(x='first_visit_date', label = i)
         plt.legend()
         plt.grid(True)
         ax = plt.gca()
         ax.grid(which='minor')
         ax.set_xlabel('Месяцы посещений')
         ax.set_ylabel('Количество посещений');
```

Вывод: с компьютеров заходят почти в три раза чаще, чем со смартфонов. На источник № 4 приходится больше всего посещений, хотя затраты на него ниже, чем на источник № 3.

Шаг 3. Напишем вывод: порекомендуем маркетологам, куда и сколько им стоит вкладывать денег?

Для определения наиболее перспективных рекламных источников сравним **ROMI** по каждому из них. Данная метрика выбрана как наиболее характерная и трудновычисляемая.

Чтобы вычислить **ROMI**, поставим каждому заказу в соответствие свой рекламный источник. Будем исходить из того, что дата и час, когда пользователь перешёл из рекламного источника, совпадают с датой и часом совершения покупки пользователем (вспомним, когда люди начинают покупать). Конечно, это предположение весьма условно: пользователь за час может перейти по нескольким ссылкам, и все они будут учтены. С другой стороны, пользователь может вспомнить о рекламе спустя несколько дней, сделать заказ, и это учтено не будет. Влияние маркетинга на заказы требует отдельного исследования, но для сравнения рекламных источников наше допущение вполне подойдёт.

Добавим столбец *source_id* в таблицу `orders_log`. Для этого вычленим дату и час начала сессии в таблице `visits_log` методом `astype('datetime64[h]')`.

```
In [86]: visits_log['hour'] = visits_log['session_start_ts'].astype('datetime64[h]')
```

Аналогично найдём дату и час заказа в таблице `orders_log`.

```
In [87]: orders_log['hour'] = orders_log['order_ts'].astype('datetime64[h]')
```

Выделим из таблицы `visits_log` нужные столбцы и сохраним в переменную `visits_source_log`.

```
In [88]: visits_source_log = visits_log[['source_id', 'user_id', 'hour']]
         visits_source_log.head()
```

Out[88]:

	source_id	user_id	hour
0	4	16879256277535980062	2017-12-20 17:00:00
1	2	104060357244891740	2018-02-19 16:00:00
2	5	7459035603376831527	2017-07-01 01:00:00
3	9	16174680259334210214	2018-05-20 10:00:00
4	3	9969694820036681168	2017-12-27 14:00:00

Объединим таблицы `orders_log` и `visits_source_log` по уникальному идентификатору пользователя и времени сессии/заказа. Удалим пропуски и дубликаты.

```
In [89]: orders_source_log = pd.merge(orders_log, visits_source_log, on=['user_id', 'hour'])
         orders_source_log = orders_source_log.dropna().drop_duplicates()
         orders_source_log.head()
```

Out[89]:

	order_ts	revenue	user_id	first_order_month	order_month	hour	source_id
0	2017-06-01 00:10:00	17.00	10329302124590727494	2017-06-01	2017-06-01	2017-06-01 00:00:00	1
1	2017-06-01 00:25:00	0.55	11627257723692907447	2017-06-01	2017-06-01	2017-06-01 00:00:00	2
2	2017-06-01 00:27:00	0.37	17903680561304213844	2017-06-01	2017-06-01	2017-06-01 00:00:00	2
3	2017-06-01 00:29:00	0.55	16109239769442553005	2017-06-01	2017-06-01	2017-06-01 00:00:00	2
4	2017-06-01 07:58:00	0.37	14200605875248379450	2017-06-01	2017-06-01	2017-06-01 07:00:00	3

Создадим функцию `find_romi_func()`.

```
In [90]: def find_romi_func(orders_log_func, monthly_costs_func):
             """
             Функция получает на вход информацию о заказах и расходы по когортам.
             Выдаёт объект Series — среднюю когорту.

             """

             # Получим месяц первой покупки каждого покупателя.
             first_orders = orders_log_func.groupby('user_id').agg({'order_month': 'min'}).reset_index()
             first_orders.columns = ['user_id', 'first_order_month']

             # Посчитаем количество новых покупателей n_buyers за каждый месяц
             cohort_sizes = first_orders.groupby('first_order_month').agg({'user_id': 'nunique'}).reset_index()
             cohort_sizes.columns = ['first_order_month', 'n_buyers']

             # Сгруппируем таблицу заказов по месяцу первой покупки и месяцу каждого заказа и сложим выручку.
             # Сбросим индекс методом reset_index()
             cohorts = orders_log_func.groupby(['first_order_month','order_month']).agg({'revenue': 'sum'}).rese
         t_index()

             # Добавим в таблицу cohorts данные о том, сколько людей первый раз совершили покупку в каждый меся
         ц.
             report = pd.merge(cohort_sizes, cohorts, on='first_order_month')

             # Добавим возраст (age) когорты.
             report['age'] = (report['order_month'] - report['first_order_month']) / np.timedelta64(1, 'M')
             report['age'] = report['age'].round().astype('int')

             # Найдём LTV, разделив валовую прибыль когорт за каждый месяц на общее число пользователей в каждой
          когорте.
             # Построим сводную таблицу.

             margin_rate = 1
             report['ltv'] = margin_rate * report['revenue'] / report['n_buyers']
             output = report.pivot_table(
                     index='first_order_month',
                     columns='age',
                     values='ltv',
                     aggfunc='mean')

             output.fillna('')

             # Посчитаем LTV каждой когорты. Сложим LTV по месяцам.
             LTV = output.sum(axis=1)

             # Добавим данные о расходах в отчёт и посчитаем CAC.
             report_new = pd.merge(report, monthly_costs_func, left_on='first_order_month', right_on='order_mont
         h')
             report_new['cac'] = report_new['costs'] / report_new['n_buyers']

             # Для расчёта ROMI поделим LTV на CAC.
             report_new['romi'] = report_new['ltv'] / report_new['cac']

             # Построим сводную таблицу и посчитаем накопительный ROMI при помощи метода cumsum().
             output_new = report_new.pivot_table(
                     index='first_order_month',
                     columns='age',
                     values='romi',
                     aggfunc='mean')

             return output_new.cumsum(axis=1).mean(axis=0)
```

Создадим пустой датафрейм `orders_source` с заголовками в виде идентификаторов рекламных источников. Отсутствует информация по расходам на источники № 6, 7, 8, поэтому они исключены.

```
In [91]: orders_source = pd.DataFrame(columns=[1, 2, 3, 4, 5, 9, 10])
         orders_source
```

Out[91]:

1	2	3	4	5	9	10

В цикле по каждому идентификатору выберем заказы и расходы по когортам, функцией `find_romi_func` посчитаем **ROMI** и добавим в датафрейм.

```
In [92]: for i in [1, 2, 3, 4, 5, 9, 10]:
             orders_source_func = orders_source_log[orders_source_log['source_id'] == i]
             monthly_costs_func = costs[costs['source_id'] == i].groupby(['order_month']).agg({'costs':'sum'})
             orders_source[i] = (find_romi_func(orders_source_func, monthly_costs_func))
             # display(i, find_romi_func(orders_source_func, monthly_costs_func))
         orders_source
```

Out[92]:

age	1	2	3	4	5	9	10
0	0.839073	0.390960	0.175169	0.450841	0.519852	0.328490	0.445319
1	0.948516	0.417437	0.180465	0.461190	0.543785	0.366268	0.453776
2	0.990084	0.483531	0.188075	0.464833	0.566198	0.397823	0.338548
3	1.040798	0.616487	0.194265	0.467563	0.595500	0.406387	0.387918
4	1.144642	0.680324	0.198199	0.476250	0.631699	0.413709	0.397906
5	1.246440	0.772923	0.207203	0.490946	0.685543	0.503059	0.357287
6	1.467653	0.734350	0.214769	0.503890	0.728370	0.491376	0.269976
7	1.593697	0.833170	0.221006	0.474268	0.812409	0.609993	0.290277
8	1.827216	0.906309	0.228066	0.449290	0.845432	0.663856	0.240584
9	1.949120	0.652019	0.213852	0.489827	0.871027	0.661332	NaN
10	2.464403	0.779290	0.227681	0.477478	0.881973	0.580920	NaN
11	2.986709	0.919016	0.212776	0.483979	1.156954	NaN	0.550601

Построим тепловую карту.

```
In [93]: plt.figure(figsize=(13, 9))
         plt.title('Окупаемость по рекламным источникам')
         sns.heatmap(orders_source, cmap='Blues', annot=True, fmt='.2f', linewidths=1, linecolor='gray', vmin=0,
          vmax=2)
         ax = plt.gca()
         ax.set_xlabel('Рекламные источники')
         ax.set_ylabel('Время жизни когорт');
```

Лучше всего окупаются рекламные источники № 1, 5 (за 4 и 10 месяцев соответственно). При этом у них низкие расходы и посещаемость, особенно у источника № 1.

Выводы

Рекламный источник № 1 обладает наибольшим потенциалом.

Пик посещения пользователей пришёлся на 24-е ноября. Средняя продолжительность сессии (ASL — average session length) составляет одну минуту.

После первого месяца количество посетителей в когорте резко снижается.

Когда люди начинают покупать? Сразу. Если они не купили ничего в первые 15 минут и не вернулись через пару дней, то, скорее всего, уже ничего не купят.

У первых покупок минимальный чек: покупатели прицениваются.

Самые прибыльные когорты — июньская и сентябрьская. LTV июньской когорты составляет меньше 12 рублей, CAC — меньше 9. Привлечение одного покупателя в среднем обошлось компании в 9 рублей. Валовая прибыль с каждого из них: 12 рублей. Вложения в привлечение покупателей окупились.

Наибольшие затраты на рекламный источник № 3. Пиковые расходы на него совпадают с пиком посещений пользователей. Самым затратным с точки зрения привлечения покупателя также является рекламный источник № 3.

С компьютеров заходят почти в три раза чаще, чем со смартфонов. На источник № 4 приходится больше всего посещений, хотя затраты на него ниже, чем на источник № 3.